

基于强化学习与蒙特卡洛树搜索的量子布尔 函数综合方法

你的名字

2026 年 7 月 1 日

1 方法

本文提出的方法将量子布尔函数综合建模为一个 ** 序列决策问题 **，并采用强化学习（RL）与蒙特卡洛树搜索（MCTS）相结合的智能框架进行求解。

1.1 问题形式化

给定一个 n 变量布尔函数的真值表 $T \in \{0, 1\}^{2^n}$ ，目标为找到一个等价的量子电路，即一个门序列 $G = (g_1, g_2, \dots, g_L)$ ，使得对应的酉矩阵 $U(G)$ 满足 $U(G)|0\rangle^{\otimes n} = |T\rangle$ （其中 $|T\rangle$ 为真值表对应的计算基态叠加）。

我们将该问题建模为 ** 马尔可夫决策过程（MDP）**，定义如下：

- **状态** s_t ：当前部分构建的电路状态，包括目标真值表 T 和当前电路的酉矩阵 U_t 。
- **动作** a_t ：从预定义动作空间 $\mathcal{A}$ 中选择一个量子门（含门类型和作用比特），即 $a_t = (\text{gate}, \text{qubits})$ 。
- **状态转移** $s_{t+1} = s_t \circ a_t$ ：即在当前电路后添加该门。

- **奖励** $R(s_t, a_t)$: 当电路构建完成（达到终止状态）时，根据最终电路的保真度 $\mathcal{F}$ 给予稀疏奖励：

$$R_{\text{final}} = \begin{cases} +1, & \mathcal{F} = 1 \quad (\text{电路完全正确}), \\ -1, & \mathcal{F} < 1 \quad (\text{电路错误}), \end{cases}$$

并可附加过程惩罚 $r_{\text{step}} = -\lambda$ 以鼓励简洁电路。

- **终止条件**: 电路深度达到预设最大值，或电路已满足目标函数。

1.2 双网络智能体架构

智能体由策略网络和价值网络构成，二者共享一个主干编码器，但输出头不同。

1.2.1 状态表示

输入状态由两部分拼接而成：

1. 目标真值表 T 的向量化表示（长度 2^n ）；
2. 当前酉矩阵 U_t 的实部与虚部展平（维度 $2 \times 2^n \times 2^n$ ）。

为避免维度过大，可在实际实现中对酉矩阵进行降维（如 PCA 或自编码器），本文采用直接展平方式以保持信息完整。

1.2.2 策略网络 $\pi_{\theta}(a|s)$

策略网络输出一个概率分布，对每个动作 $a \in \mathcal{A}$ 打分：

$$\pi_{\theta}(a|s) = \text{Softmax}(f_{\text{policy}}(h_s)),$$

其中 h_s 为共享主干提取的特征向量， f_{policy} 为若干全连接层。该输出作为 MCTS 中动作的 ** 先验概率 ** $P(s, a)$ 。

1.2.3 价值网络 $V_{\phi}(s)$

价值网络输出一个标量，预测从状态 s 出发的期望累计奖励：

$$V_{\phi}(s) = \text{Tanh}(f_{\text{value}}(h_s)),$$

其中 f_{value} 为另一组全连接层，输出经 tanh 激活以限制在 $[-1, 1]$ 。该值用于 MCTS 中的节点评估和提前终止判断。

1.3 蒙特卡洛树搜索 (MCTS)

MCTS 在每次决策时进行多步模拟，以平衡“探索”与“利用”。其核心流程包含四个阶段：

Algorithm 1: MCTS 搜索过程

Input: 当前状态 s_0 , 策略网络 π_θ , 价值网络 V_ϕ , 模拟次数 N_{sim}

Output: 改进后的动作概率分布 π (基于访问次数)

```

1 初始化搜索树, 根节点为  $s_0$ 
2 for  $i = 1$  to  $N_{\text{sim}}$  do
3    $node \leftarrow$  根节点
4   while  $node$  非叶节点 do
5     
$$a \leftarrow \arg \max_{a'} \left( Q(node, a') + c \cdot P(node, a') \cdot \frac{\sqrt{\sum_b N(node, b)}}{1 + N(node, a')} \right)$$

        // 选择阶段
6      $node \leftarrow$  子节点  $(node, a)$ 
7   if  $node$  为终止状态 then
8      $z \leftarrow R_{\text{final}}$ 
9   else
10    for 每个动作  $a'$  在动作空间中 do
11      创建新子节点  $child$ , 其先验  $P(child) = \pi_\theta(a'|s_{node})$ 
12     $z \leftarrow$  模拟  $(node)$  // 使用默认策略快速走完
        // 反向传播
13  while  $node \neq$  根节点 do
14    更新  $N(node, a) += 1$ ,  $Q(node, a) += z - V_\phi(s_{node})$ 
15     $node \leftarrow$  父节点  $(node)$ 
16 return  $\pi(a|s_0) = N(s_0, a) / \sum_b N(s_0, b)$  // 访问次数归一化
```

其中 c 为探索常数, N 为访问次数, Q 为平均价值, 模拟阶段可采用随机走子或轻量级启发式策略。

1.4 训练循环

整个系统通过“搜索-存储-学习”的闭环不断进化。训练算法如算法 ?? 所示。

Algorithm 2: 训练循环

Input: 布尔函数数据集 $\mathcal{D}$, 策略网络 π_θ , 价值网络 V_ϕ , 训练轮数 E

Output: 训练好的网络参数 θ, ϕ

1 初始化经验池 $\mathcal{B} \leftarrow \emptyset$

2 **for** $epoch = 1$ **to** E **do**

3 **foreach** 函数 $f \in \mathcal{D}$ **do**

4 使用 MCTS (算法 1) 搜索得到改进策略 π 和最终奖励 z

5 记录每一步的 (s_t, π_t, z_t) 存入 $\mathcal{B}$

6 **for** $step = 1$ **to** K **do**

7 从 $\mathcal{B}$ 中采样一批数据 (s, π, z)

8 计算损失:

$$\mathcal{L} = \frac{1}{|\text{batch}|} \sum_i \left[(z_i - V_\phi(s_i))^2 - \pi_i^\top \log \pi_\theta(s_i) \right] + \lambda \|\theta\|_2^2,$$

其中 λ 为正则系数。使用 Adam 优化器更新 θ, ϕ

9 **return** θ, ϕ

1.5 动作空间与门库

动作空间 $\mathcal{A}$ 可根据研究目标灵活配置。本文考虑以下常用门库:

- **CNT 门库:** $\{NOT, CNOT, Toffoli\}$, 适合可逆逻辑综合;
- **通用门库:** $\{H, X, Y, Z, CNOT, T, Toffoli, SWAP\}$, 表达能力最强;
- **Clifford+T 门库:** $\{H, S, CNOT, T\}$, 贴合容错计算硬件约束。

每个动作同时包含门类型和作用量子比特（如 $CNOT_{0,1}$ ），动作空间大小为 $|\text{门库}| \times n(n-1)/2$ （对于双比特门）或 $|\text{门库}| \times n$ （对于单比特门）。

1.6 复杂性分析

MCTS 每次模拟的复杂度为 $O(L \cdot |\mathcal{A}|)$ ，其中 L 为模拟深度， $|\mathcal{A}|$ 为动作空间大小；训练过程的计算成本主要取决于模拟次数和数据规模。由于策略网络和价值网络提供了先验和评估，实际搜索效率远优于穷举。

2 小结

本章详细阐述了基于 RL 与 MCTS 的量子布尔函数综合方法，包括 MDP 建模、双网络架构、MCTS 搜索算法及训练流程。该方法通过智能体的自我博弈，能够在指数级搜索空间中高效地生成高质量量子电路，为后续实验验证奠定了理论基础。