

基于强化学习与蒙特卡洛树搜索的量子布尔函数综合方法

你的名字

2026 年 7 月 1 日

1 方法

本文提出的方法将量子布尔函数综合建模为一个 ** 序列决策问题 **，并采用强化学习（RL）与蒙特卡洛树搜索（MCTS）相结合的智能框架进行求解。

1.1 问题形式化

给定一个 n 变量布尔函数的真值表 $T \in \{0, 1\}^{2^n}$ ，目标为找到一个等价的量子电路，即一个门序列 $G = (g_1, g_2, \dots, g_L)$ ，使得对应的酉矩阵 $U(G)$ 满足 $U(G)|0\rangle^{\otimes n} = |T\rangle$ （其中 $|T\rangle$ 为真值表对应的计算基态叠加）。

我们将该问题建模为 ** 马尔可夫决策过程（MDP）**，定义如下：

- **状态 s_t** ：当前部分构建的电路状态，包括目标真值表 T 和当前电路的酉矩阵 U_t 。
- **动作 a_t** ：从预定义动作空间 $\mathcal{A}$ 中选择一个量子门（含门类型和作用比特），即 $a_t = (gate, qubits)$ 。
- **状态转移 $s_{t+1} = s_t \circ a_t$** ，即在当前电路后添加该门。
- **奖励 $R(s_t, a_t)$** ：当电路构建完成（达到终止状态）时，根据最终电路的保真度 $\mathcal{F}$ 给予稀疏奖励：

$$R_{\text{final}} = \begin{cases} +1, & \mathcal{F} = 1 \quad (\text{电路完全正确}), \\ -1, & \mathcal{F} < 1 \quad (\text{电路错误}), \end{cases}$$

并可附加过程惩罚 $r_{\text{step}} = -\lambda$ 以鼓励简洁电路。

- **终止条件：** 电路深度达到预设最大值，或电路已满足目标函数。

1.2 双网络智能体架构

智能体由策略网络和价值网络构成，二者共享一个主干编码器，但输出头不同。

1.2.1 状态表示

输入状态由两部分拼接而成：

1. 目标真值表 T 的向量化表示（长度 2^n ）；
2. 当前酉矩阵 U_t 的实部与虚部展平（维度 $2 \times 2^n \times 2^n$ ）。

为避免维度过大，可在实际实现中对酉矩阵进行降维（如 PCA 或自编码器），本文采用直接展平方式以保持信息完整。

1.2.2 策略网络 $\pi_\theta(a|s)$

策略网络输出一个概率分布，对每个动作 $a \in \mathcal{A}$ 打分：

$$\pi_\theta(a|s) = \text{Softmax}(f_{\text{policy}}(h_s)),$$

其中 h_s 为共享主干提取的特征向量， f_{policy} 为若干全连接层。该输出作为 MCTS 中动作的 ** 先验概率 ** $P(s, a)$ 。

1.2.3 价值网络 $V_\phi(s)$

价值网络输出一个标量，预测从状态 s 出发的期望累计奖励：

$$V_\phi(s) = \text{Tanh}(f_{\text{value}}(h_s)),$$

其中 f_{value} 为另一组全连接层，输出经 $\tanh$ 激活以限制在 $[-1, 1]$ 。该值用于 MCTS 中的节点评估和提前终止判断。

1.3 蒙特卡洛树搜索（MCTS）

MCTS 在每次决策时进行多步模拟，以平衡“探索”与“利用”。其核心流程包含四个阶段：

Algorithm 1: MCTS 搜索过程

Input: 当前状态 s_0 ，策略网络 π_θ ，价值网络 V_ϕ ，模拟次数 N_{sim}
Output: 改进后的动作概率分布 π （基于访问次数）

```

1 初始化搜索树，根节点为  $s_0$  ;
2 for  $i = 1$  to  $N_{\text{sim}}$  do
3    $node \leftarrow$  根节点 ;
4   while  $node$  非叶节点 do
5      $a \leftarrow$ 
        $\arg \max_{a'} \left( Q(node, a') + c \cdot P(node, a') \cdot \frac{\sqrt{\sum_b N(node, b)}}{1 + N(node, a')} \right)$  ;
       // 选择阶段
6      $node \leftarrow$  子节点( $node, a$ ) ;
7   end
8   if  $node$  为终止状态 then
9      $z \leftarrow R_{\text{final}}$  ;
10  end
11 else
12   for 每个动作  $a'$  在动作空间中 do
13     创建新子节点  $child$ ，其先验  $P(child) = \pi_\theta(a'|s_{node})$  ;
14   end
15    $z \leftarrow$  模拟( $node$ ) ;           // 使用默认策略快速走完
16 end
17 ;                               // 反向传播
18 while  $node \neq$  根节点 do
19   更新  $N(node, a) += 1$ ,  $Q(node, a) += z - V_\phi(s_{node})$  ;
20    $node \leftarrow$  父节点( $node$ ) ;
21 end
22 return  $\pi(a|s_0) = N(s_0, a) / \sum_b N(s_0, b)$  ;           // 访问次数归一化

```

其中 c 为探索常数， N 为访问次数， Q 为平均价值，模拟阶段可采用

随机走子或轻量级启发式策略。

1.4 训练循环

整个系统通过“搜索—存储—学习”的闭环不断进化。训练算法如算法 ?? 所示。

Algorithm 2: 训练循环

Input: 布尔函数数据集 $\mathcal{D}$, 策略网络 π_θ , 价值网络 V_ϕ , 训练轮数 E

Output: 训练好的网络参数 θ, ϕ

```

1 初始化经验池  $\mathcal{B} \leftarrow \emptyset$ ;
2 for  $epoch = 1$  to  $E$  do
3   foreach 函数  $f \in \mathcal{D}$  do
4     使用 MCTS (算法 1) 搜索得到改进策略  $\pi$  和最终奖励  $z$ ;
5     记录每一步的  $(s_t, \pi_t, z_t)$  存入  $\mathcal{B}$ ;
6   end
7   for  $step = 1$  to  $K$  do
8     从  $\mathcal{B}$  中采样一批数据  $(s, \pi, z)$ ;
9     计算损失:
          
$$\mathcal{L} = \frac{1}{|\text{batch}|} \sum_i [(z_i - V_\phi(s_i))^2 - \pi_i^\top \log \pi_\theta(s_i)] + \lambda \|\theta\|_2^2,$$

          其中  $\lambda$  为正则系数。使用 Adam 优化器更新  $\theta, \phi$ ;
10    end
11 end
12 return  $\theta, \phi$ 

```

1.5 动作空间与门库

动作空间 $\mathcal{A}$ 可根据研究目标灵活配置。本文考虑以下常用门库:

- **CNT 门库:** $\{NOT, CNOT, Toffoli\}$, 适合可逆逻辑综合;
- **通用门库:** $\{H, X, Y, Z, CNOT, T, Toffoli, SWAP\}$, 表达能力最强;
- **Clifford+T 门库:** $\{H, S, CNOT, T\}$, 贴合容错计算硬件约束。

每个动作同时包含门类型和作用量子比特（如 $CNOT_{0,1}$ ），动作空间大小为 $|\text{门库}| \times n(n-1)/2$ （对于双比特门）或 $|\text{门库}| \times n$ （对于单比特门）。

1.6 复杂性分析

MCTS 每次模拟的复杂度为 $O(L \cdot |\mathcal{A}|)$ ，其中 L 为模拟深度， $|\mathcal{A}|$ 为动作空间大小；训练过程的计算成本主要取决于模拟次数和数据规模。由于策略网络和价值网络提供了先验和评估，实际搜索效率远优于穷举。

2 小结

本章详细阐述了基于 RL 与 MCTS 的量子布尔函数综合方法，包括 MDP 建模、双网络架构、MCTS 搜索算法及训练流程。该方法通过智能体的自我博弈，能够在指数级搜索空间中高效地生成高质量量子电路，为后续实验验证奠定了理论基础。