

面向资源约束量子布尔函数综合的神经蒙特卡洛树搜索方法： 自适应布尔环筛选的阶段性证据

中文技术论文稿 v4

2026 年 7 月 8 日

摘要

量子布尔函数 oracle 综合需要把经典谓词嵌入可逆量子线路, 其逻辑层 T-count、CNOT、深度和辅助比特数会直接影响后续容错资源估计。直接代数正规形 (algebraic normal form, ANF) 综合语义清晰, 但会重复计算大量高次数 AND 结构; SSHR 等 CNOT-oriented 方法提供了重要小规模 baseline, 却不同于本文希望研究的资源加权搜索问题。本文将 oracle 综合建模为 ANF/固定极性 Reed-Muller (fixed-polarity Reed-Muller, FPRM) 项集合上的组合优化, 提出由资源感知候选分解、神经动作先验、蒙特卡洛树搜索、baseline-preserving guard、Pareto portfolio 和布尔环线性因子筛选组成的逻辑层综合框架。最新实验显示, 在 $n \leq 6$ 的 177 个传统函数上, Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平, 平均 score 降低 36.09%; 相对 weighted ESOP-MILP 获得 167/3/7, 平均 score 降低 29.84%。在 $n = 18$ 的 12 个随机 ANF 函数上, adaptive depth-2 布尔环筛选相对单层筛选获得 11/0/1, 平均 score 降低 6.47%; 完整 Resource-NMCTS 相对 adaptive screen 进一步降低 23.85%, 说明中等高维仍需要深搜索。在 $n = 20$ 的 6 个边界函数上, depth-2 布尔环筛选相对单层筛选获得 5/0/1, 平均 score 降低 7.47%; 集成到 Resource-NMCTS 后, 相对 AND-direct ANF 获得 5/0/1, 平均 score 降低 11.80%。进一步的结构级策略网络在 $n = 14, 16, 18$ 上训练、在 held-out $n = 20$ 上测试, 能够相对单层和 depth-1 screen 分别降低 6.57% 和 2.57% 的平均 score, 并比全 depth adaptive 评估节省 34.71% 时间, 但相对固定 depth-2 screen 仍有 0.28% 的 score 缺口。这些结果说明, 本文路线已经从复现 SSHR 转为独立的逻辑层资源搜索方法; 但高维 learned prior 的独立收益仍需继续放大, 外部 reversible-toolchain 对比和函数级线路案例仍需补齐。

关键词: 量子 oracle 综合; 布尔函数综合; 神经蒙特卡洛树搜索; 布尔环; ANF; FPRM; T-count

术语与主张边界

术语	本文中的固定含义
Resource-NMCTS	以 ANF/FPRM 项集合为搜索状态、使用资源加权 score 选择候选线路的逻辑层综合框架。
Pareto-Resource-NMCTS	在 Resource-NMCTS 外层保留多资源候选并按最终 score 选择的 portfolio 版本。
Boolean-ring screen	在 square-free Boolean ring 语义下筛选线性因子，允许线性因子与 quotient 共享变量。
baseline guard	即 baseline-preserving guard：同时运行确定性候选和学习候选，只接受不劣于 baseline 的结果，用于抑制神经先验负迁移。
depth policy	结构级神经策略，输入 ANF 项集合统计特征，输出 single/depth-1/depth-2 screen 的选择。

本文只讨论逻辑层资源，不包含硬件 mapping、连通性约束、routing、容错调度或物理噪声模型。本文的当前目标不是证明 CNOT-only 最优，而是在同一逻辑资源模型下获得更低 T-count 和更低加权 score。

1 引言

给定布尔函数 $f : \{0, 1\}^n \rightarrow \{0, 1\}$ ，量子 oracle 通常实现为

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle. \quad (1)$$

这类 oracle 是 Grover 搜索、量子密码分析和多种量子算法子程序中的基本组件。由于容错量子计算中非 Clifford 门代价高，oracle 的 T-count、T-depth、CNOT、逻辑深度和辅助比特数不应被视为后端细节，而是决定算法资源估计可信度的核心指标。

最直接的输入表示是 ANF。若

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i, \quad (2)$$

则每个单项式都可以被翻译为可逆乘法结构，并异或到输出位。直接 ANF 综合的优势是简单、稳定、语义透明；缺点是不同单项式之间的公共 AND 结构、线性奇偶结构和极性重写机会很难被自动复用。对于随机高维项集合，这种重复计算会迅速推高 T-count。

已有 XAG、ROS、BDD 和 SSHR 等路线从不同中间表示处理 oracle synthesis 问题 [2, 3, 4, 6]。本文并不从 SSHR 的 parallelotope cover 空间出发，也不把目标设为在 CNOT 数上全面超过 SSHR；SSHR 在本文中是 CNOT-oriented small-scale baseline。本文的核心主题是把量子布尔函数综合表述为资源加权搜索问题，并结合 AI 搜索方法在 ANF/FPRM 项集合上选择可复用因子。

本文的一句话论证是：在逻辑层量子布尔函数 oracle 综合中，ANF/FPRM 项集合上的资源感知搜索，配合布尔环线性因子筛选和保守 portfolio 选择，可以在传统小规模函数和 $n = 18, 20$ 高维随机函数上降低 T-count 与加权逻辑资源；当前边界是神经先验尚未形成足够大的独立贡献，且结论不覆盖硬件 mapping。

2 相关工作与问题定位

Xor-And-Inverter Graphs (XAG) 把 XOR 与 AND 结构分离, 使 AND 节点数量与非 Clifford 资源直接相关。Meuli 等人将 XAG 用于 quantum compilation[2], 并从 multiplicative complexity 角度解释低 T-count oracle 的来源 [1]。ROS 将 oracle synthesis 建模为 resource-constrained LUT mapping[3]。BDD-based reversible synthesis 使用决策图处理较大布尔函数 [4]。这些工作说明, 中间表示会决定可暴露的共享结构。

强化学习和树搜索已经用于经典布尔电路、Clifford+T unitary、ZX-calculus rewrite 和量子线路 ordering 等任务 [7, 8, 9, 10]。这些工作支持“学习式搜索适合组合综合空间”这一方向, 但它们的动作空间与本文不同。本文动作不是一般 unitary gate、ZX rewrite rule 或 Pauli rotation ordering, 而是 Boolean oracle 中项集合的因子选择、极性重写和可逆复用。

因此, 本文的 AI 角色应当写得保守: 神经模型是候选扩展器和排序器, MCTS 是受预算约束的组合搜索器, baseline-preserving guard 是防止负迁移的保护层。当前数据还不足以把 learned prior 写成唯一主贡献。

3 资源模型与搜索状态

本文输入为布尔函数的真值表或 ANF 表示, 输出为实现式 (1) 的逻辑层可逆线路。每条候选线路都必须通过 truth-table 级语义验证。候选选择使用统一逻辑资源分数

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (3)$$

式 (3) 是可复现的逻辑层比较准则, 不代表具体硬件平台的真实物理成本。因此实验报告同时列出 T-count、CNOT、depth、gates 和 peak ancilla, 避免单一 score 掩盖资源 trade-off。

Resource-NMCTS 的搜索状态是当前尚未综合的项集合 $\mathcal{M}$ 。动作是选择一个可计算、可反算的局部因子结构, 把项集合分解为 quotient 子问题和 rest 子问题, 再递归处理。候选动作包括公共单项式因子、固定极性重写后的公共因子、CNOT-only 线性因子、布尔环线性因子, 以及由神经模型重排或扩展的 root action。相对于直接在真值表上训练黑盒策略, 这种状态保留了布尔代数结构, 也使每一步都可以翻译为线路片段。

4 方法

4.1 资源感知分解

直接 ANF 综合把每个单项式单独计算到输出位。若多个单项式共享高次数因子, 则可以先计算该因子, 再用较低成本的 quotient 子问题复用它。FPRM 极性搜索进一步改变项集合形状, 使原始 ANF 中不明显的公共结构变得显式。低维传统函数上的大幅收益主要来自仿射坐标搜索、FPRM 极性、MCTS 子问题选择和 portfolio 的组合, 而不是单一 rollout。

神经动作先验使用候选覆盖率、项数变化、平均次数、因子大小、即时资源收益和子问题规模等特征为动作排序。MCTS 在固定预算内探索候选组合, 并用 rollout 估计后续资源代价。由于高

维 learned prior 有负迁移风险，当前实现采用 baseline-preserving guard：确定性候选与神经候选并行产生，最终保留 score 更低者。

4.2 布尔环线性因子

旧 linear-pair 分支主要搜索形如

$$(x_i \oplus x_j \oplus \dots) \cdot h(x) \quad (4)$$

的局部结构，并要求线性因子变量与 quotient $h(x)$ 变量不相交。这个约束便于实现，但会漏掉 square-free Boolean ring 中合法的重叠变量结构。本文使用布尔环线性因子允许二者共享变量，并在展开时利用 $x_i^2 = x_i$ 和 GF(2) 偶数项消去。例如

$$(x_i \oplus x_j)x_im = x_im \oplus x_ix_jm. \quad (5)$$

线路层面仍可先用 CNOT 计算线性奇偶量，再用该辅助量控制 quotient 子线路。因此，这一扩展不是单纯增加 top- k 宽度，而是把 Boolean algebra 中原本被实现约束排除的候选重新纳入搜索。

4.3 自适应 depth-2 筛选

在 $n = 20$ 边界切片中，FPRM root beam 和 fast linear-pair 均出现 300 s task timeout。为降低长尾，本文新增自适应布尔环筛选：先评估单层 Boolean-ring screen，再评估 depth-1 recursive screen 和 depth-2 recursive screen，最后按式 (3) 选择资源分数最低的候选。该策略不做昂贵 FPRM 极性枚举，主要在原始 ANF 上进行快速结构筛选。

自适应筛选的定位有两个层次。第一，它是一个独立快速候选，适合在超高维函数上提供不超时的 baseline-preserving 改进。第二，它可以作为 Resource-NMCTS portfolio 的高维分支，使完整方法在旧 root beam 或旧 linear-pair 超时的区域仍有可验证输出。

5 实验设计

实验分为五组。第一组是 $n \leq 6$ 的 177 个传统函数，用于和 direct ANF、AND-direct ANF、ESOP cube beam、ESOP-MILP、SSHR-H、ABC 和 BDD baseline 比较。第二组是高维随机 ANF 压力测试，重点观察 $n = 16$ 、 $n = 18$ 和 $n = 20$ 的扩展性。第三组是 matched comparison 消融，用函数名配对，比较相同函数上的 T-count、CNOT、depth、ancilla、score 和时间。第四组是结构级 depth policy 诊断，用 $n = 14, 16, 18$ 训练、held-out $n = 20$ 测试，判断神经策略能否选择 screen 深度。第五组是负面结果和边界审计，用来判断哪些主张不能写过头。

所有内部结果均来自已经生成的 CSV、manifest 和分析脚本。高维切片中出现 timeout 的方法保留错误行，不纳入 correct matched comparison；因此本文对 $n = 20$ 的结论限定为“可运行边界上的资源改进”，而不是“完整全局搜索最优”。

表 1: $n \leq 6$ 传统函数切片上的平均逻辑资源。

方法	平均 T	平均 CNOT	平均 depth	平均 ancilla	平均 score
Direct ANF	184.1	134.2	134.6	1.33	194.3
AND-direct ANF	101.0	166.5	166.9	2.18	115.2
Resource-NMCTS	43.9	89.9	94.5	1.92	53.2
Pareto-Resource-NMCTS	40.4	83.0	88.0	2.03	49.6
ESOP-MILP	83.6	133.5	159.6	2.32	96.7
SSHR-H	81.0	67.6	88.7	1.36	88.2

表 2: $n = 18$ 随机 ANF 函数上的布尔环筛选与完整 Resource-NMCTS。

方法	平均 T	平均 CNOT	平均 depth	平均 score	平均时间 (s)
单层 Boolean screen	10389.33	16268.42	16268.50	11349.06	0.815
Adaptive depth-2 screen	9767.00	15301.58	15301.67	10670.94	4.390
Resource-NMCTS	6639.33	11380.92	11382.17	7315.62	226.179

6 结果

6.1 传统函数上的主结果

表 1 给出 $n \leq 6$ 传统函数上的平均资源。相对 direct ANF, Pareto-Resource-NMCTS 平均 T-count 降低 72.25%, 平均 score 降低 67.80%。相对 ESOP cube beam, Pareto-Resource-NMCTS 获得 174/0/3 的 score 胜/负/平, 平均 score 降低 36.09%。相对 weighted ESOP-MILP, 获得 167/3/7, 平均 score 降低 29.84%。

SSHR-H 的平均 CNOT 最低, 说明本文不能主张 CNOT-only 支配。更准确的写法是: 在当前逻辑层加权资源模型下, 本文方法以更多结构搜索和一定辅助比特为代价, 换取更低 T-count 与更低综合 score。

6.2 $n = 18$ 高维压力测试

表 2 汇总 $n = 18$ 的最新可追溯结果。单层布尔环筛选平均 score 为 11349.06; adaptive depth-2 筛选降至 10670.94。相对单层筛选, adaptive depth-2 筛选获得 11/0/1, 平均 T-count 降低 6.58%, CNOT 和 depth 均降低 5.99%, score 降低 6.47%。完整 Resource-NMCTS 的平均 score 为 7315.62, 相对 adaptive screen 进一步降低 23.85%, 说明 $n = 18$ 上快速 screen 是低成本候选生成器, 但不能替代完整搜索。

这个结果有双重含义。正向来看, adaptive depth-2 布尔环筛选是一个低成本、稳定改善单层筛选的结构模块。负向来看, 完整 Resource-NMCTS 相对 adaptive screen 的平均 score 仍低 23.85%。因此, ANF-only screen 不能替代完整 Resource-NMCTS, 只能作为高维快速候选或 portfolio 分支。

表 3: $n = 20$ 边界函数上的最新自适应筛选结果。

方法	T	CNOT	depth	score	时间 (s)
Direct ANF	42944.00	19600.33	19600.33	44037.63	10.524
AND-direct ANF	21516.67	33635.67	33635.67	23491.15	10.492
Single screen	20786.00	32492.50	32492.50	22695.15	10.836
Depth-1 screen	20138.00	31480.50	31480.50	21988.52	12.732
Depth-2 / adaptive	19535.33	30542.50	30542.50	21331.24	20.152
Resource-NMCTS adaptive	19535.33	30542.50	30542.50	21331.24	79.554

表 4: $n = 20$ matched comparison。负的平均变化表示目标方法更优。

比较	函数数	score 胜/负/平	平均 Δ score
Depth-2 screen vs depth-1 screen	6	5/0/1	-3.13%
Adaptive screen vs single screen	6	5/0/1	-7.47%
Adaptive Resource-NMCTS vs AND-direct ANF	6	5/0/1	-11.80%
Adaptive Resource-NMCTS vs adaptive screen	6	0/0/6	0.00%

6.3 $n = 20$ 边界测试

$n = 20$ 切片更接近当前方法的边界。FPRM root beam 和 fast linear-pair 在此前运行中均出现 300 s task timeout。最新 depth-2 筛选结果显示，其平均 score 为 21331.24，低于单层 screen 的 22695.15 和 depth-1 screen 的 21988.52。相对单层 screen，depth-2 screen 获得 5/0/1，平均 T-count 降低 7.64%，CNOT 和 depth 均降低 6.65%，score 降低 7.47%。

表 4 给出 matched comparison。相对 AND-direct ANF，集成自适应分支的 Resource-NMCTS 获得 5/0/1，平均 T-count 降低 12.24%，CNOT 和 depth 均降低 11.02%，score 降低 11.80%。相对 depth-1 screen，depth-2 screen 再降低 3.13% 的 score。该结果表明 depth-2 布尔环筛选确实带来新增量，而不是单层 screen 的重复表述。

最后一行也很关键：在这组 $n = 20$ 函数上，完整 Resource-NMCTS 的最终资源与 adaptive screen 相同，但运行时间更长。这说明当前 $n = 20$ 收益主要来自布尔环筛选，而不是更深的 MCTS 搜索。论文中应把这组实验写成“可扩展候选生成的成功”，而不是“高维神经 MCTS 已经充分成功”。

为了控制这一运行时长尾，当前实现还加入了一个可解释的 screen-gate。该门控由 18 个 $n = 18, 20$ 配对样本训练得到，判断何时可以跳过完整 Resource-NMCTS tail。在 $n = 20$ 的 6 个边界函数上，screen-gated Resource-NMCTS 与完整 Resource-NMCTS 的 T、CNOT、depth、peak ancilla 和 score 全部持平，平均运行时间从 77.10 s 降到 31.18 s，相对变化为 -61.31%。由于该门控训练样本仍很少，本文只把它作为高维运行时控制证据，而不把它写成普适质量模型。

6.4 结构级 depth policy

为把 AI 贡献从动作排序推进到结构选择，本文训练了一个轻量策略网络，输入 ANF 项集合的次数分布、变量/二元共现密度、root Boolean-ring action 统计等结构特征，输出 single、depth-1 或 depth-2 screen。训练集包含 240 个 $n = 14, 16, 18$ 合成高维项集，验证集 72 个同分布项集；测试集为 48 个 held-out $n = 20$ 项集。监督标签由真实运行三种 screen 并按式 (3) 选择最低 score 产

表 5: 结构级 depth policy 在 held-out $n = 20$ 项集上的比较。

比较	函数数	score 胜/负/平	平均 Δ score	平均 Δ time
Policy vs single screen	48	42/0/6	-6.57%	+2224.00%
Policy vs depth-1 screen	48	34/0/14	-2.57%	+257.27%
Policy vs depth-2 screen	48	0/5/43	+0.28%	-10.85%
Policy vs all-depth adaptive	48	0/5/43	+0.28%	-34.71%

生。

表 5 显示, depth policy 在 held-out $n = 20$ 上的 oracle-depth 命中率为 79.2%。相对固定 single screen, policy 获得 42/0/6、平均 score 降低 6.57%; 相对固定 depth-1 screen, 获得 34/0/14、平均 score 降低 2.57%。相对全 depth adaptive 评估, policy 的平均 score 只高 0.28%, 但运行时间降低 34.71%。这说明结构级 AI 已能学习“何时需要更深筛选”的趋势。

这组结果必须谨慎解释。它是正向的结构级 AI 证据, 因为 policy 明确优于较浅固定策略, 并显著减少全 depth adaptive 的评估时间; 但它还不是最终主贡献, 因为固定 depth-2 screen 仍在 score 上略好。下一阶段应把 depth policy 与 baseline-preserving guard 结合, 目标是在保持不劣于 depth-2 的前提下减少运行时间, 并进一步学习是否进入 FPRM polarity search 或完整 Resource-NMCTS。

7 负面结果与边界

当前最重要的不足有三点。第一, 高维 learned prior 的独立收益仍小。已有 pairwise-wide root-action ranker 在 $n = 16$ full synthesis 上相对 deterministic recursive guard 的平均 score 降幅约为 0.18%, 新 depth policy 相对全 depth adaptive 有 34.71% 的时间优势, 但相对固定 depth-2 screen 仍有 0.28% 的 score 缺口。这些结果说明 AI 模块已经开始做结构选择, 但还不足以作为显著资源收益的唯一主贡献。第二, 布尔环筛选虽然在 $n = 18$ 和 $n = 20$ 上稳定改善单层筛选, 但在 $n = 18$ 仍明显弱于完整 Resource-NMCTS。这说明筛选分支是低成本结构补丁, 不是完整搜索替代物。第三, 本文目前只处理逻辑层资源, 没有做 mapping、routing、连通性约束、容错调度或真实硬件噪声模型, 因此不能把结论扩展为硬件后端最优。

这些边界不会推翻本文路线, 但会决定写法。最稳妥的主张是: 本文提出一种独立于 SSHR 的逻辑层资源搜索框架, 在传统函数和高维随机 ANF 边界上展示可验证的资源降低; 同时, AI 模块已经从动作排序推进到结构级 depth policy, 但还需要形成不劣于强确定性 guard 的质量收益, 才能成为论文的主要创新点。

8 下一步工作

若以“明显提升”为目标结束点, 当前工作还不应停止。下一阶段应优先完成三项工作。

第一, 继续升级结构级策略网络。当前 depth policy 已经证明模型能在 held-out $n = 20$ 上学习 screen 深度, 但还没有超过固定 depth-2 的 score。下一步不应只提高分类准确率, 而应训练带 guard 的策略: 当 policy 选择较浅 screen 时, 用低成本校验或双分支兜底保证不劣于 depth-2; 当

结构特征显示 depth-2 不够时, 再预测是否进入 FPRM polarity search 或完整 Resource-NMCTS。

第二, 补外部 reversible-toolchain 对比。已有 ESOP、ABC、BDD 和 SSHR baseline 可以支撑第一版方法论文, 但审稿人可能要求与 ROS、mockturtle、RevKit 或 back-end-aware oracle synthesis 更贴近的比较。即使最终不能完全复现, 也应给出环境审计、可运行子集或不可比原因。

第三, 补函数级线路案例。当前表格结果足够多, 但缺少一个能让读者直观看到方法机制的案例: direct ANF 如何重复计算 AND, FPRM root beam 如何改变项集合, Boolean-ring factor 如何捕获重叠变量结构, 以及 guard 如何选择最终线路。该案例会显著增强论文可信度。

9 结论

本文给出一条面向资源约束量子布尔函数综合的逻辑层搜索路线: 以 ANF/FPRM 项集合为状态, 以资源分数为选择准则, 用神经先验和 MCTS 生成候选, 并用 baseline-preserving guard 与 Pareto portfolio 保持结果稳健。最新结果显示, adaptive depth-2 布尔环筛选在 $n = 18$ 相对单层筛选降低 6.47% 的平均 score, depth-2 布尔环筛选在 $n = 20$ 相对单层筛选降低 7.47%, 并使集成 Resource-NMCTS 相对 AND-direct ANF 降低 11.80%。结构级 depth policy 进一步说明神经模型可以学习 screen 深度选择, 在 held-out $n = 20$ 上接近 adaptive oracle 并减少评估时间; 但它尚未超过固定 depth-2 的 score。这些结果已经能支撑一篇中文技术论文稿的主体论证; 但要达到更强投稿目标, 还需要带 guard 的结构级神经策略、外部工具链对比和函数级案例解释。

参考文献

- [1] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.
- [2] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.
- [3] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained oracle synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.
- [4] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, pp. 270–275, 2009.
- [5] M. Yu, A. Tempia Calvino, M. Soeken, and G. De Micheli. Back-end-aware fault-tolerant quantum oracle synthesis. In *Proceedings of ASP-DAC*, pp. 930–937, 2025.
- [6] Q. Zheng, Y. Xu, J. Zhang, Z. Su, and S. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. In *Proceedings of ICCAD*, 2025.
- [7] D. Tsaras, A. Grosnit, L. Chen, Z. Xie, H. Bou-Ammar, and M. Yuan. ShortCircuit: AlphaZero-driven synthesis of Boolean circuits. *arXiv:2408.09858*, 2024.

- [8] S. Rietsch, A. Y. Dubey, C. Ufrecht, M. Periyasamy, A. Plinge, C. Mutschler, and D. D. Scherer. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *IEEE International Conference on Quantum Computing and Engineering*, pp. 824–835, 2024.
- [9] J. Riu, J. Nogu  , G. Vilaplana, A. Garcia-Saez, and M. P. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [10] M. Machiya, M. Menickelly, P. Hovland, and J. Liu. MonteQ: A Monte Carlo tree search based quantum circuit synthesis framework. *arXiv:2604.19029*, 2026.