

面向资源约束量子布尔函数综合的神经蒙特卡洛树搜索方法

中文正式论文初稿 v2

2026 年 7 月 7 日

摘要

量子布尔函数 oracle 综合把经典谓词嵌入可逆量子线路，是量子搜索、量子密码分析和若干算法原语中的关键编译步骤。直接由代数正规形 (algebraic normal form, ANF) 生成线路具有语义透明性，但在高次数项和稠密项集合上会产生大量重复计算，并推高 T-count。本文提出 Resource-NMCTS，将 oracle 综合表述为 ANF/固定极性 Reed-Muller (fixed-polarity Reed-Muller, FPRM) 项集合上的资源约束因子搜索问题。该方法以公共因子、线性因子、Boolean-ring linear screen 和 compute/uncompute 复用作为动作空间，结合神经动作先验、蒙特卡洛树搜索、baseline-preserving guard 与 Pareto 候选库，在统一逻辑资源模型下选择正确线路。实验覆盖 $n \leq 6$ 的 177 个传统函数、 $n = 14$ 至 $n = 20$ 的高维随机 ANF 压力测试、ESOP/ABC/BDD/SSHR baseline、搜索消融和小规模 exact 参照。在传统函数切片上，Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平，平均 score 降低 36.09%；相对 weighted ESOP-MILP 获得 167/3/7，平均 score 降低 29.84%。在 $n = 18$ 的 12 个函数上，Resource-NMCTS 相对 direct ANF 平均 T-count 降低 60.05%，平均 score 降低 56.99%。 $n = 20$ 边界测试显示，传统 FPRM root-beam 与 fast linear-pair 在 300 s 预算下全部超时；加入 ANF Boolean-ring linear screen 后，Resource-NMCTS 相对 AND-direct ANF 获得 5/0/1 的 score 胜/负/平，平均 score 进一步降低 4.89%。这些结果表明，面向 ANF/FPRM 项集合的资源感知神经搜索可以稳定降低逻辑层 T-count 与加权资源；同时，本文不主张 CNOT-only 全面最优，也不覆盖硬件映射、连通性约束或真实噪声模型。

关键词：量子 oracle 综合；布尔函数综合；神经蒙特卡洛树搜索；ANF；FPRM；T-count；资源约束

1 引言

给定布尔函数 $f : \{0, 1\}^n \rightarrow \{0, 1\}$ ，量子 oracle 通常实现为

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle. \quad (1)$$

这类结构是 Grover 搜索、量子密码分析和一系列量子算法子程序中的核心部件。由于容错量子计算中非 Clifford 资源通常昂贵，oracle 的 T-count、T-depth、CNOT、线路深度和辅助比特数会直接影响算法级资源估计。因此，布尔 oracle 综合不应只回答“是否正确实现函数”，还应回答“在给定的逻辑资源模型下是否比已有综合路线更节省资源”。

直接由 ANF 构造 oracle 是最自然的基线。若

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i, \quad (2)$$

则每个单项式可以被翻译为可逆乘法结构，并异或到输出位。然而，这种逐项综合忽略了不同单项式之间的共享结构。对于高次数项、随机项集合或高维函数，重复计算会使 T-count 快速增长。已有 XAG、LUT、BDD 和 SSHR 等路线分别从不同布尔表示和搜索空间处理这一问题 [1, 3, 4, 6]。这些工作共同说明：布尔函数的中间表示和搜索动作决定了量子 oracle 的逻辑资源结构。

本文关注一个更直接的问题：是否可以不依赖 SSHR 的 parallelotope cover 空间，而直接在 ANF/FPRM 项集合上搜索可复用因子，并用 AI 搜索机制稳定改善逻辑层资源？为此，本文提出 Resource-NMCTS。它把候选因子视为搜索动作，用神经先验和 MCTS 改善动作排序，再用 baseline-preserving guard 和 Pareto portfolio 避免单一启发式在部分函数族上退化。本文贡献如下。

1. 提出面向 ANF/FPRM 项集合的资源约束 oracle 综合框架，将公共因子、线性因子、FPRM 极性和 compute/uncompute 复用纳入同一搜索空间。
2. 设计神经动作先验与 MCTS 结合的搜索流程，并用 baseline-preserving AI guard 将不稳定的神经排序转化为无 score-loss 的保守增益。
3. 在 177 个 $n \leq 6$ 传统函数、 $n = 14$ 至 $n = 18$ 高维随机 ANF、ESOP/ABC/BDD/SSHR baseline、消融实验和 exact 小规模参照上给出统一逻辑资源评估。
4. 明确给出方法边界：本文主张逻辑层低 T-count 和低加权资源优势，不主张 CNOT-only 全面支配、硬件映射最优或任意规模全局最优。

2 相关工作

2.1 布尔表示驱动的 oracle 综合

Xor-And-Inverter Graphs (XAG) 把 XOR 与 AND 结构分离，使 AND 节点数量与非 Clifford 代价产生直接联系。Meuli 等人提出将 XAG 用于量子编译中的 oracle 构造 [1]，并从 multiplicative complexity 角度分析低 T-count oracle 的来源 [2]。ROS 将 oracle synthesis 建模为 resource-constrained LUT mapping 与层次化综合问题 [3]。这些工作与本文共同强调布尔表示的重要性，但本文不以 XAG 或 LUT 为唯一中间表示，而是直接在 ANF/FPRM 项集合上搜索可复用因子。

BDD-based reversible synthesis 使用决策图处理大规模布尔函数 [4]。Back-end-aware oracle synthesis 进一步将 XAG-based oracle optimization 与后端感知质量指标连接起来 [5]。本文与这些工作互补：本文只处理逻辑层资源估计，不覆盖后端映射、routing、真实噪声和容错调度。

2.2 SSHR 与 small-scale Boolean synthesis

SSHR 使用 parallelotope 空间结构进行 small-scale Boolean function synthesis，重点优化 CNOT 指标 [6]。本文保留 SSHR-H/SSHR-I 作为 CNOT-oriented baseline，但方法内部不使用 parallelotope candidate set。这个区分很重要：本文不是“AI-SSHR”，而是面向 ANF/FPRM 因子空间的神经资源搜索。SSHR 对本文的价值在于提供一个小规模 CNOT 优势基线，帮助揭示本文方法在 T-count/score 上的收益和在 CNOT-only 指标上的 trade-off。

表 1: 本文主张、证据和边界。

主张	当前证据	边界
低 T-count 与低 score	传统函数、ESOP/ABC/BDD/SSHR baseline、高维随机 ANF 压力测试	不等价于硬件映射后资源最优
搜索模块有独立贡献	仿射搜索、neural refine、guard、Pareto archive 和 high-dimensional linear-pair guard 的 matched ablation	高维 learned prior 仍是弱正向结果
方法独立于 SSHR	内部空间为 ANF/FPRM 因子分解, 不使用 parallelotope cover	SSHR 仍需作为 CNOT-oriented baseline 比较
高维可扩展性	$n = 16$ 24 个函数和 $n = 18$ 12 个函数完成真值表验证	不提供全局最优性证书

2.3 AI 搜索与量子线路综合

强化学习和树搜索已经用于多个综合任务。ShortCircuit 使用 AlphaZero 风格搜索生成经典布尔电路 [7]; Gumbel AlphaZero 被用于 Clifford+T unitary synthesis[8]; ZX-calculus 优化中出现了 PPO 和图神经网络驱动的 rewrite-rule 选择 [9]; MonteQ 使用 MCTS 处理量子线路综合中的动作排序 [10]。这些工作说明学习式搜索可以处理组合综合空间。本文的差异在于搜索对象: 本文不是一般 unitary、ZX rewrite graph 或 Pauli rotation ordering, 而是 Boolean oracle synthesis 中的 ANF/FPRM 项集合因子化。

3 问题定义与资源模型

本文输入为布尔函数 f 的真值表或 ANF 表示, 输出为实现式 (1) 的逻辑层可逆量子线路。所有候选线路必须通过 exhaustive truth-table simulation 验证语义正确。对于高维随机 ANF 函数, 实验仍保留真值表级验证路径, 因此报告的资源改进不是仅由符号表达式估算得到。

候选线路使用如下统一逻辑资源分数进行选择:

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (3)$$

其中 T 表示 T-count, depth 表示逻辑层深度估计, ancilla 表示 peak ancilla。式 (3) 是可复现的逻辑层候选选择准则, 而不是某个具体硬件平台的真实物理成本。为避免结论被某一组权重绑定, 本文还对 T-only、CNOT-depth 和 ancilla-tight 等替代权重进行事后重算。

表 1 给出本文主张、证据和边界。本文把“可证明全局最优”和“在同一 benchmark 上稳定改善资源”区分开来, 后者才是当前实验能够支撑的论断。

4 方法

4.1 ANF/FPRM 因子搜索空间

Resource-NMCTS 的基本观察是：ANF 项集合中常存在可复用的公共结构。若若干项共享因子 $g(x)$ ，可以先把 $g(x)$ 计算到辅助比特，再在多个剩余子项中复用，最后 uncompute。这样做通常增加少量 CNOT、深度或辅助比特，但可以显著减少重复的多控制乘法结构，从而降低 T-count。

FPRM 极性搜索进一步改变项集合形状。固定某些变量的极性，相当于在布尔表达中重写变量出现方式，可能暴露 ANF 中不可见的公共因子。与只在原始坐标上搜索相比，FPRM 极性和仿射坐标变换扩大了可见结构空间，是传统函数切片上主要收益来源之一。

高维随机 ANF 中，linear-pair 因子尤其重要。若局部项集合可写作

$$(x_i \oplus x_j \oplus \dots) \cdot h(x), \quad (4)$$

则线性部分可由 CNOT-only 结构计算，不直接增加 T-count。recursive linear-pair guard 在子问题中继续寻找这种结构；fast guard 则用更保守的 bounded search 控制 $n = 18$ 以上切片的运行时间。

为处理更高维的压力切片，本文进一步加入 ANF Boolean-ring linear screen。该分支仍搜索线性因子，但允许 quotient monomial 与线性因子共享变量，并在展开时使用布尔环规则 $x_i^2 = x_i$ 与 GF(2) 偶数项消去。screen 版本只评估单层候选，并以 direct plan 为 baseline，因此在 $n = 20$ 上避免了 FPRM 极性筛选和 root-beam 的长尾；它的目标不是替代深递归搜索，而是在超高维场景中提供一个可验证、低开销、baseline-preserving 的结构候选。

4.2 神经动作先验与 MCTS

搜索状态为当前尚未综合的项集合，动作为选择一个候选因子并递归处理剩余项。动作特征包括项数、平均次数、候选覆盖率、因子大小、即时资源收益和子问题规模等。神经动作先验根据这些特征给候选动作排序；MCTS 在固定预算内探索不同因子组合，并通过 rollout 估计候选动作的后续资源代价。

在低维和中等规模函数上，learned prior 为 Resource-NMCTS 提供了小但稳定的正向信号。在 $n \leq 6$ 传统函数 rerun 中，learned prior for Resource-NMCTS 相对无 learned prior 的 score 胜/负/平为 39/0/138，平均 score 降低 1.10%。然而，高维场景中单独神经排序并不稳定。 $n = 16$ 结果显示，root-neural recursive guard 相对 deterministic recursive guard 的 score 胜/负/平为 6/7/11，平均 score 反而增加 0.08%。

因此本文采用 baseline-preserving AI guard：同时运行 deterministic recursive guard 和 root-neural recursive guard，并保留 score 更低者。该策略牺牲部分运行时间，换取无 score-loss 的保守增益。在 $n = 16$ 的 24 个函数上，AI guard 相对 deterministic recursive guard 获得 6/0/18，平均 score 降低 0.05%。

4.3 Portfolio 与 Pareto archive

单一搜索器无法在所有函数族上稳定最优。本文采用 resource-aware portfolio: direct ANF、AND-direct ANF、FPRM root beam、linear-pair guard、Affine-NMCTS、Resource-NMCTS 和 Pareto-Resource-NMCTS 等候选被共同生成, 然后按式 (3) 选择正确且分数最低的线路。对于小规模函数, Pareto archive 保留 T-count、CNOT、depth、gate count 和 ancilla 等多资源维度上的非支配候选。对于高维函数, Pareto 分支会被 bounded guard 收窄, 因此高维结果应写成 scalability/guard 证据, 而不是独立 Pareto superiority 证据。

5 实验设置

5.1 Benchmark

实验包含四类数据。第一类是 $n \leq 6$ 的 177 个传统函数, 用于与 direct ANF、AND-direct ANF、固定坐标 MCTS、ESOP cube beam、ESOP-MILP、SSHR-H 和外部 ABC/BDD/SSHR 结果比较。第二类是中高维随机 ANF 压力测试, 包括 $n = 14$ 的 64 个函数、 $n = 15$ 的 32 个函数、 $n = 16$ 的 24 个函数、 $n = 18$ 的 12 个函数, 以及 $n = 20$ 的 6 个边界函数。第三类是外部 baseline, 包括 ABC-AIG、ABC-XAG、ABC-LUT、BDD/Shannon、ABC-ESOP 和 SSHR-I。第四类是小规模 exact 参照, 包括 exact FPRM-DP 和 exact XAG multiplicative complexity 下界。

所有内部结果均记录在 CSV 与 manifest 中, 并由分析脚本生成表格。传统函数切片包含 1770 行方法结果, $n = 16$ 切片包含 240 行结果, $n = 18$ 切片包含 84 行结果。报告时同时给出 T-count、CNOT、depth、peak ancilla 和 score, 避免用单一 score 掩盖资源 trade-off。

5.2 Baseline 与公平性

direct ANF 和 AND-direct ANF 是语义透明基线; FPRM root beam 和 linear-pair guard 是本文内部结构搜索基线; ESOP cube beam 和 ESOP-MILP 提供传统 ESOP 路线参照; SSHR-H/SSHR-I 提供 CNOT-oriented small-scale 参照; ABC 与 BDD 提供外部逻辑网络和决策图参照。对于高维随机函数, SSHR-I 和 ESOP-MILP 受候选规模或 ILP 时间限制, 因此不作为全部高维切片的主要 baseline。

6 结果

6.1 传统函数切片

表 2 给出 $n \leq 6$ 传统函数切片上的平均资源。Pareto-Resource-NMCTS 取得最低平均 T-count、最低平均 depth 和最低平均 score。相对 direct ANF, Pareto-Resource-NMCTS 的平均 T-count 降低 72.25%, 平均 score 降低 67.80%。相对 ESOP cube beam, Pareto-Resource-NMCTS 的 score 胜/负/平为 174/0/3, 平均 score 降低 36.09%; 相对 weighted ESOP-MILP 为 167/3/7, 平均 score 降低 29.84%。

SSHR-H 的平均 CNOT 为 67.6, 低于 Pareto-Resource-NMCTS 的 83.0。这说明本文方法并

表 2: $n \leq 6$ 传统函数切片上的平均逻辑资源。

方法	平均 T	平均 CNOT	平均 depth	平均 ancilla	平均 score
Direct ANF	184.1	134.2	134.6	1.33	194.3
AND-direct ANF	101.0	166.5	166.9	2.18	115.2
Affine-NMCTS	45.9	94.4	98.9	1.88	55.4
Resource-NMCTS	43.9	89.9	94.5	1.92	53.2
Pareto-Resource-NMCTS	40.4	83.0	88.0	2.03	49.6
ESOP-MILP	83.6	133.5	159.6	2.32	96.7
SSHR-H	81.0	67.6	88.7	1.36	88.2

表 3: 搜索贡献分解。负的平均变化表示目标方法更优。

对比	score 胜/负/平	平均 Δ score
Affine greedy vs fixed-coordinate MCTS	165/88/68	-12.12%
Neural refine over affine greedy	65/0/257	-1.08%
Guarded Affine-NMCTS over no-guard	88/0/234	-1.74%
Resource-NMCTS over Affine-NMCTS	44/0/133	-1.91%
Pareto archive over Resource-NMCTS	68/0/109	-3.26%
Pareto Resource-NMCTS over no-MCTS portfolio	106/0/71	-4.69%

不在 CNOT-only 指标上全面支配 SSHR。更准确的结论是：在相同传统函数集合上，Resource-NMCTS 与 Pareto-Resource-NMCTS 用更高或相近的 Clifford/辅助结构换取显著更低的 T-count 和加权 score。

6.2 搜索贡献分解

表 3 显示，资源下降不是单个启发式偶然造成的。仿射坐标搜索是最大前置收益；neural refine 和 guarded MCTS 是小幅但无 score-loss 的增益；Pareto archive 在小规模函数上提供清晰的 portfolio 改善；高维切片中的主要规模机制来自 bounded linear-pair guard。

6.3 高维随机 ANF 压力测试

表 4 汇总高维随机 ANF 切片的主要比较。 $n = 14$ 和 $n = 15$ 说明 linear-pair guard 是高维主要规模机制； $n = 16$ 说明 recursive guard 与 baseline-preserving AI guard 的组合有效； $n = 18$ 说明 Resource-NMCTS 在更大随机 ANF 上仍能完成真值表验证并改善 root beam。

从 direct ANF 角度看，高维结果更显著。 $n = 16$ 的 24 个函数上，Resource-NMCTS 平均 T-count 降低 63.36%，平均 score 降低 60.83%； $n = 18$ 的 12 个函数上，平均 T-count 降低 60.05%，平均 score 降低 56.99%。代价是 peak ancilla 通常上升，且相对 direct ANF 的 CNOT/depth 在部分函数上变差。这是典型的逻辑资源 trade-off：本文方法主要减少昂贵的非 Clifford 结构，而不是单独最小化所有资源。

$n = 20$ 结果应单独解释。该切片包含 6 个随机 ANF 函数、8 个方法、48 行结果，其中 12 行为 timeout：FPRM root beam 和 fast linear-pair 在所有 6 个函数上均触发 300 s task timeout。

表 4: 高维随机 ANF 压力测试中的主要比较。

规模	对比	函数数	score 胜/负/平	平均 Δ score
$n = 14$	Linear-pair guard vs root beam	64	60/0/4	-3.00%
$n = 15$	Recursive guard vs root beam	32	30/0/2	-5.28%
$n = 16$	Resource-NMCTS vs root beam	24	23/0/1	-4.36%
$n = 16$	AI guard vs recursive guard	24	6/0/18	-0.05%
$n = 18$	Fast guard vs root beam	12	6/0/6	-1.91%
$n = 18$	Resource-NMCTS vs fast guard	12	12/0/0	-3.55%
$n = 20$	Resource-NMCTS vs direct ANF	6	5/1/0	-34.00%
$n = 20$	Resource-NMCTS vs AND-direct ANF	6	5/0/1	-4.89%

表 5: 不同资源权重下的紧凑 score 比较。每个单元为胜/负/平与平均相对变化。

比较	Paper score	T-only	CNOT-depth	Ancilla-tight
$n \leq 6$: ESOP cube beam	174/0/3, -36.09%	174/0/3, -38.95%	174/0/3, -32.08%	174/0/3, -32.75%
$n \leq 6$: ESOP-MILP	167/3/7, -29.84%	166/0/11, -32.77%	165/4/8, -25.44%	167/3/7, -26.68%
$n \leq 6$: SSHR-H	173/4/0, -41.06%	173/0/4, -47.93%	168/9/0, -27.87%	172/5/0, -31.95%
$n = 16$: FPRM root beam	23/0/1, -4.36%	23/0/1, -4.70%	23/0/1, -4.28%	23/0/1, -3.43%
$n = 18$: FPRM root beam	12/0/0, -5.29%	12/0/0, -6.19%	12/0/0, -4.54%	11/1/0, -3.33%

ANF Boolean-ring linear screen 完成 6/6, 并把 Resource-NMCTS、Profile-Resource-NMCTS 和 Pareto-Resource-NMCTS 从原先的 AND-direct 退化状态中拉出: 相对 AND-direct ANF, 三者获得 5/0/1 的 score 胜/负/平, 平均 T-count 降低 5.24%, 平均 score 降低 4.89%。因此, $n = 20$ 现在可以写成可扩展 screen 带来的边界改善; 但它仍不是强高维神经搜索证据, 因为收益来自单层代数 screen, 而不是 learned prior 或深 FPRM tree search。

6.4 资源权重鲁棒性

表 5 给出不同权重下的紧凑比较。传统函数结果在 T-only、CNOT-depth 和 ancilla-tight 权重下仍保持优势; 高维结果相对 root beam 也保持正向。CNOT-depth 权重会缩小 SSHR-H 对比中的优势, 因为 SSHR-H 本身是 CNOT-oriented 方法。这进一步说明本文应把主张限定为低 T-count 与低加权资源, 而不是 CNOT-only 全面优越。

6.5 高维神经先验的边界

本文的 AI 证据需要谨慎表达。在 $n \leq 6$ 传统函数上, learned prior 是正向信号; 但在高维随机 ANF 上, 当前模型仍不足以作为强 AI 主张。pairwise root-action ranker 把 $n = 14$ learned prior 相对 no-prior 的 score 胜/负/平从 1/0/11 改善到 2/0/10, 平均 score 降低 0.04%, 但运行时间增加 124.91%。root-action oracle 诊断显示, 宽 root-action set 内确实存在排序 headroom, 例

如 oracle top-24 相对 heuristic top-1 为 7/0/3, 平均 score 降低 0.43%。这说明高维 AI 排序有继续提升空间, 但当前最终 synthesis 收益仍小。

7 讨论

本文结果支持一个明确但有边界的结论: Resource-NMCTS 能在逻辑层 Boolean oracle synthesis 中稳定降低 T-count 和加权 score。传统函数切片给出最强统计证据, 高维随机 ANF 切片说明 bounded linear-pair guard 和 resource-aware portfolio 可以扩展到更大变量数, 权重鲁棒性分析说明结论不依赖单一 score 权重。

第一个限制是 CNOT trade-off。SSHR-H 在传统函数上的平均 CNOT 更低, 因此若目标是 CNOT-only, SSHR 仍然是强 baseline。本文方法更适合 T-count 或综合 score 更重要的场景。第二个限制是高维 learned prior 的收益仍小。baseline-preserving AI guard 能保证无 score-loss 小增益, 但这还不是“神经模型显著主导高维搜索”的证据。第三个限制是 $n = 20$ 压力测试仍然暴露当前实现的规模边界: FPRM root-beam 与 fast linear-pair 均超时, ANF Boolean-ring screen 虽能带来 4.89% 的平均 score 改善, 但 Resource/Profile/Pareto 在该切片上与 screen 候选完全一致, 尚未形成更深 tree search 的额外分离。第四个限制是本文只处理逻辑层资源, 没有硬件 coupling graph、routing、容错调度或噪声模型。第五个限制是外部 reversible-toolchain 对比仍可加强, 特别是 ROS、mockturtle 或 RevKit 风格流程。

下一步最有价值的提升方向有三点。第一, 训练更强的 high-dimensional root-action/value ranker, 使用更宽 teacher、top-k distillation 和 pairwise/listwise 混合损失, 把当前 0.04% 的高维 learned-prior 改善提升到可见量级。第二, 补充可复现的外部 reversible-toolchain baseline, 减少审稿人对工具链覆盖不足的质疑。第三, 加入代表性函数案例, 展示 direct ANF、root beam、linear-pair guard 和 Resource-NMCTS 如何在项集合层面产生不同因子分解, 从而解释 T-count 降低的机制。

8 结论

本文提出 Resource-NMCTS, 将量子布尔函数 oracle 综合建模为 ANF/FPRM 项集合上的资源约束神经搜索问题。通过公共因子、线性因子、Boolean-ring linear screen、FPRM 极性、神经动作先验、MCTS、baseline-preserving guard 和 Pareto portfolio, 本文在传统函数和高维随机 ANF 上获得了低 T-count 与低加权逻辑资源优势。当前证据足以支持逻辑层方法论文的主线, 但不足以支持硬件映射最优、CNOT-only 全面支配或高维神经先验已经显著领先的强结论。后续工作应集中在更强高维排序模型、外部 reversible-toolchain 对比和可解释线路案例上。

参考文献

- [1] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.
- [2] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.

- [3] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained oracle synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.
- [4] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, pp. 270–275, 2009.
- [5] N. Yu, L. Tempia Calvino, M. Soeken, and G. De Micheli. Back-end-aware fault-tolerant quantum oracle synthesis. In *Proceedings of ASP-DAC*, 2025.
- [6] Q. Zheng, Y. Xu, J. Zhang, Z. Su, and S. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. *arXiv:2509.01912*, 2025.
- [7] D. Tsaras, A. Grosnit, L. Chen, Z. Xie, H. Bou-Ammar, and M. Yuan. ShortCircuit: AlphaZero-driven synthesis of Boolean circuits. *arXiv:2408.09858*, 2024.
- [8] P. Rietsch, C. T. Hann, M. Soeken, and M. Roetteler. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *IEEE International Conference on Quantum Computing and Engineering*, 2024.
- [9] D. Riu, G. Nogue, J. Vilaplana, A. Garcia-Saez, and M. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [10] H. Machiya, M. Menickelly, P. Hovland, and X. Liu. MonteQ: A Monte Carlo tree search based quantum circuit synthesis framework. *arXiv:2604.19029*, 2026.