

# 自适应布尔环筛选增强的资源约束量子布尔函数综合方法

中文技术论文稿 v4

2026 年 7 月 7 日

## 摘要

量子布尔函数 oracle 综合需要把经典谓词嵌入可逆量子线路, 其逻辑层 T-count、CNOT、深度和辅助比特数会直接影响后续容错资源估计。直接代数正规形 (algebraic normal form, ANF) 综合语义清晰, 但会重复计算大量高次数 AND 结构; SSHR 等 CNOT-oriented 方法提供了重要小规模 baseline, 却不同于本文希望研究的资源加权搜索问题。本文将 oracle 综合建模为 ANF/固定极性 Reed-Muller (fixed-polarity Reed-Muller, FPRM) 项集合上的组合优化, 提出由资源感知候选分解、神经动作先验、蒙特卡洛树搜索、baseline-preserving guard、Pareto portfolio 和自适应布尔环线性因子筛选组成的逻辑层综合框架。最新实验显示, 在  $n \leq 6$  的 177 个传统函数上, Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平, 平均 score 降低 36.09%; 相对 weighted ESOP-MILP 获得 167/3/7, 平均 score 降低 29.84%。在  $n = 18$  的 12 个随机 ANF 函数上, 自适应 depth-2 布尔环筛选相对单层筛选获得 11/0/1, 平均 score 降低 6.45%; 完整 Resource-NMCTS 相对该快速筛选仍进一步降低 23.87%。在  $n = 20$  的 6 个边界函数上, 自适应 depth-2 布尔环筛选相对单层筛选获得 5/0/1, 平均 score 降低 7.41%; 集成到 Resource-NMCTS 后, 相对 AND-direct ANF 获得 5/0/1, 平均 score 降低 11.74%。这些结果说明, 本文路线已经从复现 SSHR 转为独立的逻辑层资源搜索方法; 但高维 learned prior 的独立收益仍小, 外部 reversible-toolchain 对比和函数级线路案例仍需补齐。

**关键词:** 量子 oracle 综合; 布尔函数综合; 神经蒙特卡洛树搜索; 布尔环; ANF; FPRM; T-count

## 1 引言

给定布尔函数  $f : \{0, 1\}^n \rightarrow \{0, 1\}$ , 量子 oracle 通常实现为

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle. \quad (1)$$

这类 oracle 是 Grover 搜索、量子密码分析和多种量子算法子程序中的基本组件。由于容错量子计算中非 Clifford 门代价高, oracle 的 T-count、T-depth、CNOT、逻辑深度和辅助比特数不应被视为后端细节, 而是决定算法资源估计可信度的核心指标。

最直接的输入表示是 ANF。若

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i, \quad (2)$$

则每个单项式都可以被翻译为可逆乘法结构, 并异或到输出位。直接 ANF 综合的优势是简单、稳定、语义透明; 缺点是不同单项式之间的公共 AND 结构、线性奇偶结构和极性重写机会很难被自动复用。对于随机高维项集合, 这种重复计算会迅速推高 T-count。

已有 XAG、ROS、BDD 和 SSHR 等路线从不同中间表示处理 oracle synthesis 问题 [2, 3, 4, 6]。本文并不从 SSHR 的 parallelotope cover 空间出发,也不把目标设为在 CNOT 数上全面超过 SSHR; SSHR 在本文中是 CNOT-oriented small-scale baseline。本文的核心主题是把量子布尔函数综合表述为资源加权搜索问题,并结合 AI 搜索方法在 ANF/FPRM 项集合上选择可复用因子。

本文的一句话论证是:在逻辑层量子布尔函数 oracle 综合中,ANF/FPRM 项集合上的资源感知搜索,配合自适应布尔环线性因子筛选和保守 portfolio 选择,可以在传统小规模函数和  $n = 18, 20$  高维随机函数上降低 T-count 与加权逻辑资源;当前边界是神经先验尚未形成足够大的独立贡献,且结论不覆盖硬件 mapping。

## 2 相关工作与问题定位

Xor-And-Inverter Graphs (XAG) 把 XOR 与 AND 结构分离,使 AND 节点数量与非 Clifford 资源直接相关。Meuli 等人将 XAG 用于 quantum compilation[2],并从 multiplicative complexity 角度解释低 T-count oracle 的来源 [1]。ROS 将 oracle synthesis 建模为 resource-constrained LUT mapping[3]。BDD-based reversible synthesis 使用决策图处理较大布尔函数 [4]。这些工作说明,中间表示会决定可暴露的共享结构。

强化学习和树搜索已经用于经典布尔电路、Clifford+T unitary、ZX-calculus rewrite 和量子线路 ordering 等任务 [7, 8, 9, 10]。这些工作支持“学习式搜索适合组合综合空间”这一方向,但它们的动作空间与本文不同。本文动作不是一般 unitary gate、ZX rewrite rule 或 Pauli rotation ordering,而是 Boolean oracle 中项集合的因子选择、极性重写和可逆复用。

因此,本文的 AI 角色应当写得保守:神经模型是候选扩展器和排序器,MCTS 是受预算约束的组合搜索器,baseline-preserving guard 是防止负迁移的保护层。当前数据还不足以把 learned prior 写成唯一主贡献。

## 3 资源模型与搜索状态

本文输入为布尔函数的真值表或 ANF 表示,输出为实现式 (1) 的逻辑层可逆线路。每条候选线路都必须通过 truth-table 级语义验证。候选选择使用统一逻辑资源分数

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (3)$$

式 (3) 是可复现的逻辑层比较准则,不代表具体硬件平台的真实物理成本。因此实验报告同时列出 T-count、CNOT、depth、gates 和 peak ancilla,避免单一 score 掩盖资源 trade-off。

Resource-NMCTS 的搜索状态是当前尚未综合的项集合  $\mathcal{M}$ 。动作是选择一个可计算、可反算的局部因子结构,把项集合分解为 quotient 子问题和 rest 子问题,再递归处理。候选动作包括公共单项式因子、固定极性重写后的公共因子、CNOT-only 线性因子、布尔环线性因子,以及由神经模型重排或扩展的 root action。相对于直接在真值表上训练黑盒策略,这种状态保留了布尔代数结构,也使每一步都可以翻译为线路片段。

## 4 方法

### 4.1 资源感知分解

直接 ANF 综合把每个单项式单独计算到输出位。若多个单项式共享高次数因子，则可以先计算该因子，再用较低成本的 quotient 子问题复用它。FPRM 极性搜索进一步改变项集合形状，使原始 ANF 中不明显的公共结构变得显式。低维传统函数上的大幅收益主要来自仿射坐标搜索、FPRM 极性、MCTS 子问题选择和 portfolio 的组合，而不是单一 rollout。

神经动作先验使用候选覆盖率、项数变化、平均次数、因子大小、即时资源收益和子问题规模等特征为动作排序。MCTS 在固定预算内探索候选组合，并用 rollout 估计后续资源代价。由于高维 learned prior 有负迁移风险，当前实现采用 baseline-preserving guard：确定性候选与神经候选并行产生，最终保留 score 更低者。

### 4.2 布尔环线性因子

旧 linear-pair 分支主要搜索形如

$$(x_i \oplus x_j \oplus \dots) \cdot h(x) \quad (4)$$

的局部结构，并要求线性因子变量与 quotient  $h(x)$  变量不相交。这个约束便于实现，但会漏掉 square-free Boolean ring 中合法的重叠变量结构。本文使用布尔环线性因子允许二者共享变量，并在展开时利用  $x_i^2 = x_i$  和 GF(2) 偶数项消去。例如

$$(x_i \oplus x_j)x_i m = x_i m \oplus x_i x_j m. \quad (5)$$

线路层面仍可先用 CNOT 计算线性奇偶量，再用该辅助量控制 quotient 子线路。因此，这一扩展不是单纯增加 top- $k$  宽度，而是把 Boolean algebra 中原本被实现约束排除的候选重新纳入搜索。

### 4.3 自适应 depth-2 筛选

在  $n = 20$  边界切片中，FPRM root beam 和 fast linear-pair 均出现 300 s task timeout。为降低长尾，本文新增自适应布尔环筛选：先评估单层 Boolean-ring screen，再评估 depth-1 recursive screen 和 depth-2 recursive screen，最后按式 (3) 选择资源分数最低的候选。该策略不做昂贵 FPRM 极性枚举，主要在原始 ANF 上进行快速结构筛选。

自适应筛选的定位有两个层次。第一，它是一个独立快速候选，适合在超高维函数上提供不超时的 baseline-preserving 改进。第二，它可以作为 Resource-NMCTS portfolio 的高维分支，使完整方法在旧 root beam 或旧 linear-pair 超时的区域仍有可验证输出。

## 5 实验设计

实验分为四组。第一组是  $n \leq 6$  的 177 个传统函数，用于和 direct ANF、AND-direct ANF、ESOP cube beam、ESOP-MILP、SSHR-H、ABC 和 BDD baseline 比较。第二组是高维随机 ANF 压力测试，重点观察  $n = 16$ 、 $n = 18$  和  $n = 20$  的扩展性。第三组是 matched comparison 消融，

表 1:  $n \leq 6$  传统函数切片上的平均逻辑资源。

| 方法                    | 平均 T        | 平均 CNOT     | 平均 depth    | 平均 ancilla | 平均 score    |
|-----------------------|-------------|-------------|-------------|------------|-------------|
| Direct ANF            | 184.1       | 134.2       | 134.6       | 1.33       | 194.3       |
| AND-direct ANF        | 101.0       | 166.5       | 166.9       | 2.18       | 115.2       |
| Resource-NMCTS        | 43.9        | 89.9        | 94.5        | 1.92       | 53.2        |
| Pareto-Resource-NMCTS | <b>40.4</b> | 83.0        | <b>88.0</b> | 2.03       | <b>49.6</b> |
| ESOP-MILP             | 83.6        | 133.5       | 159.6       | 2.32       | 96.7        |
| SSHR-H                | 81.0        | <b>67.6</b> | 88.7        | 1.36       | 88.2        |

表 2:  $n = 18$  随机 ANF 函数上的布尔环筛选与完整 Resource-NMCTS。

| 方法                        | 平均 T           | 平均 CNOT         | 平均 depth        | 平均 score       | 平均时间 (s) |
|---------------------------|----------------|-----------------|-----------------|----------------|----------|
| 单层 Boolean screen         | 10389.33       | 16268.42        | 16268.50        | 11349.06       | 0.823    |
| Depth-1 Boolean screen    | 10060.67       | 15757.92        | 15758.00        | 10991.33       | 1.404    |
| Depth-2 / adaptive screen | 9768.67        | 15303.67        | 15303.75        | 10672.55       | 2.993    |
| Resource-NMCTS            | <b>6639.33</b> | <b>11380.92</b> | <b>11382.17</b> | <b>7315.62</b> | 227.402  |

用函数名配对, 比较相同函数上的 T-count、CNOT、depth、ancilla、score 和时间。第四组是负面结果和边界审计, 用来判断哪些主张不能写过头。

所有内部结果均来自已经生成的 CSV、manifest 和分析脚本。高维切片中出现 timeout 的方法保留错误行, 不纳入 correct matched comparison; 因此本文对  $n = 20$  的结论限定为“可运行边界上的资源改进”, 而不是“完整全局搜索最优”。

## 6 结果

### 6.1 传统函数上的主结果

表 1 给出  $n \leq 6$  传统函数上的平均资源。相对 direct ANF, Pareto-Resource-NMCTS 平均 T-count 降低 72.25%, 平均 score 降低 67.80%。相对 ESOP cube beam, Pareto-Resource-NMCTS 获得 174/0/3 的 score 胜/负/平, 平均 score 降低 36.09%。相对 weighted ESOP-MILP, 获得 167/3/7, 平均 score 降低 29.84%。

SSHR-H 的平均 CNOT 最低, 说明本文不能主张 CNOT-only 支配。更准确的写法是: 在当前逻辑层加权资源模型下, 本文方法以更多结构搜索和一定辅助比特为代价, 换取更低 T-count 与更低综合 score。

### 6.2 $n = 18$ 高维压力测试

表 2 汇总  $n = 18$  的最新结果。单层布尔环筛选平均 score 为 11349.06; depth-1 筛选降至 10991.33; depth-2 与自适应筛选降至 10672.55。自适应筛选相对单层筛选获得 11/0/1, 平均 T-count 降低 6.56%, CNOT 和 depth 均降低 5.97%, score 降低 6.45%。

这个结果有双重含义。正向来看, depth-2 自适应筛选是一个低成本、稳定改善单层筛选的结构

表 3:  $n = 20$  边界函数上的最新自适应筛选结果。

| 方法                      | T               | CNOT            | depth           | score           | 时间 (s) |
|-------------------------|-----------------|-----------------|-----------------|-----------------|--------|
| Direct ANF              | 42944.00        | 19600.33        | 19600.33        | 44037.63        | 10.416 |
| AND-direct ANF          | 21516.67        | 33635.67        | 33635.67        | 23491.15        | 10.428 |
| Single screen           | 20786.00        | 32492.50        | 32492.50        | 22695.15        | 10.749 |
| Depth-1 screen          | 20138.00        | 31480.50        | 31480.50        | 21988.52        | 12.246 |
| Depth-2 / adaptive      | <b>19542.00</b> | <b>30553.00</b> | <b>30553.00</b> | <b>21338.52</b> | 16.539 |
| Resource-NMCTS adaptive | <b>19542.00</b> | <b>30553.00</b> | <b>30553.00</b> | <b>21338.52</b> | 75.836 |

表 4:  $n = 20$  matched comparison。负的平均变化表示目标方法更优。

| 比较                                         | 函数数 | score 胜/负/平 | 平均 $\Delta$ score |
|--------------------------------------------|-----|-------------|-------------------|
| Depth-2 screen vs depth-1 screen           | 6   | 5/0/1       | -3.07%            |
| Adaptive screen vs single screen           | 6   | 5/0/1       | -7.41%            |
| Adaptive Resource-NMCTS vs AND-direct ANF  | 6   | 5/0/1       | -11.74%           |
| Adaptive Resource-NMCTS vs adaptive screen | 6   | 0/0/6       | 0.00%             |

模块。负向来看, 完整 Resource-NMCTS 相对自适应筛选仍获得 11/0/1, 平均 score 再降低 23.87%。因此, ANF-only screen 不能替代完整 Resource-NMCTS, 只能作为高维快速候选或 portfolio 分支。

### 6.3 $n = 20$ 边界测试

$n = 20$  切片更接近当前方法的边界。FPRM root beam 和 fast linear-pair 在此前运行中均出现 300 s task timeout。最新自适应筛选结果显示, depth-2/adaptive screen 的平均 score 为 21338.52, 低于单层 screen 的 22695.15 和 depth-1 screen 的 21988.52。相对单层 screen, 自适应筛选获得 5/0/1, 平均 T-count 降低 7.58%, CNOT 和 depth 均降低 6.59%, score 降低 7.41%。

表 4 给出 matched comparison。相对 AND-direct ANF, 集成自适应分支的 Resource-NMCTS 获得 5/0/1, 平均 T-count 降低 12.18%, CNOT 和 depth 均降低 10.97%, score 降低 11.74%。相对 depth-1 screen, depth-2 screen 再降低 3.07% 的 score。该结果表明 depth-2 布尔环筛选确实带来新增量, 而不是单层 screen 的重复表述。

最后一行也很关键: 在这组  $n = 20$  函数上, 完整 Resource-NMCTS 的最终资源与 adaptive screen 相同, 但运行时间更长。这说明当前  $n = 20$  收益主要来自布尔环筛选, 而不是更深的 MCTS 搜索。论文中应把这组实验写成“可扩展候选生成的成功”, 而不是“高维神经 MCTS 已经充分成功”。

## 7 负面结果与边界

当前最重要的不足有三点。第一, 高维 learned prior 的独立收益仍小。已有 pairwise-wide root-action ranker 在  $n = 16$  full synthesis 上相对 deterministic recursive guard 的平均 score 降幅约为 0.18%, 属于可信但不够显著的 AI 证据。第二, 自适应布尔环筛选虽然在  $n = 18$  和  $n = 20$  上稳定改善单层筛选, 但在  $n = 18$  仍明显弱于完整 Resource-NMCTS。这说明筛选分支是低成本结构

补丁，不是完整搜索替代物。第三，本文目前只处理逻辑层资源，没有做 mapping、routing、连通性约束、容错调度或真实硬件噪声模型，因此不能把结论扩展为硬件后端最优。

这些边界不会推翻本文路线，但会决定写法。最稳妥的主张是：本文提出一种独立于 SSHR 的逻辑层资源搜索框架，在传统函数和高维随机 ANF 边界上展示可验证的资源降低；同时，AI 模块还需要从动作排序升级为结构级策略，才能成为论文的主要创新点。

## 8 下一步工作

若以“明显提升”为目标结束点，当前工作还不应停止。下一阶段应优先完成三项工作。

第一，训练结构级策略网络。模型不应只排序已有 root action，而应预测何时使用 Boolean-ring factor、何时进入 FPRM polarity search、何时停止递归，以及是否接受更高 peak ancilla 换取更低 T-count。监督信号可以来自现有 matched comparison，也可以从  $n = 14, 16, 18, 20$  的 root-action 诊断中构造 pairwise ranking 数据。

第二，补外部 reversible-toolchain 对比。已有 ESOP、ABC、BDD 和 SSHR baseline 可以支撑第一版方法论文，但审稿人可能要求与 ROS、mockturtle、RevKit 或 back-end-aware oracle synthesis 更贴近的比较。即使最终不能完全复现，也应给出环境审计、可运行子集或不可比原因。

第三，补函数级线路案例。当前表格结果足够多，但缺少一个能让读者直观看到方法机制的案例：direct ANF 如何重复计算 AND，FPRM root beam 如何改变项集合，Boolean-ring factor 如何捕获重叠变量结构，以及 guard 如何选择最终线路。该案例会显著增强论文可信度。

## 9 结论

本文给出一条面向资源约束量子布尔函数综合的逻辑层搜索路线：以 ANF/FPRM 项集合为状态，以资源分数为选择准则，用神经先验和 MCTS 生成候选，并用 baseline-preserving guard 与 Pareto portfolio 保持结果稳健。最新自适应 depth-2 布尔环筛选在  $n = 18$  相对单层筛选降低 6.45% 的平均 score，在  $n = 20$  相对单层筛选降低 7.41%，并使集成 Resource-NMCTS 相对 AND-direct ANF 降低 11.74%。这些结果已经能支撑一篇中文技术论文稿的主体论证；但要达到更强投稿目标，还需要结构级神经策略、外部工具链对比和函数级案例解释。

## 参考文献

- [1] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.
- [2] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.
- [3] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained oracle synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.

- [4] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, pp. 270–275, 2009.
- [5] M. Yu, A. Tempia Calvino, M. Soeken, and G. De Micheli. Back-end-aware fault-tolerant quantum oracle synthesis. In *Proceedings of ASP-DAC*, pp. 930–937, 2025.
- [6] Q. Zheng, Y. Xu, J. Zhang, Z. Su, and S. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. In *Proceedings of ICCAD*, 2025.
- [7] D. Tsaras, A. Grosnit, L. Chen, Z. Xie, H. Bou-Ammar, and M. Yuan. ShortCircuit: AlphaZero-driven synthesis of Boolean circuits. *arXiv:2408.09858*, 2024.
- [8] S. Rietsch, A. Y. Dubey, C. Ufrecht, M. Periyasamy, A. Plinge, C. Mutschler, and D. D. Scherer. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *IEEE International Conference on Quantum Computing and Engineering*, pp. 824–835, 2024.
- [9] J. Riu, J. Nogué, G. Vilaplana, A. Garcia-Saez, and M. P. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [10] M. Machiya, M. Menickelly, P. Hovland, and J. Liu. MonteQ: A Monte Carlo tree search based quantum circuit synthesis framework. *arXiv:2604.19029*, 2026.