

面向资源约束量子布尔函数综合的神经蒙特卡洛树搜索方法

中文技术论文草稿

2026 年 7 月 7 日

摘要

量子布尔函数 oracle 综合需要把经典谓词嵌入可逆量子线路，其逻辑层资源成本直接影响后续容错实现中的 T-count、CNOT、深度和辅助比特需求。已有方法分别从 XAG、LUT、BDD、SSHR parallelotope 和一般量子线路强化学习等角度改进综合质量，但仍缺少一个直接面向 ANF/FPRM 项集合、以多资源目标为核心、并可扩展到高维随机布尔函数的神经搜索框架。本文提出 Resource-NMCTS，将 oracle 综合表述为 ANF/FPRM 因子分解上的资源约束搜索问题，结合仿射坐标预处理、固定极性 Reed-Muller 极性搜索、linear-pair guard、神经动作先验、蒙特卡洛树搜索和 Pareto 候选库，在统一逻辑资源模型下选择候选线路。当前实验覆盖 $n \leq 6$ 的 177 个传统函数、 $n = 14, 15, 16, 18$ 的高维随机 ANF 压力测试、ESOP/ABC/BDD/SSHR 外部基线、搜索贡献消融，以及 exact FPRM-DP 和 exact XAG 小规模参照。在传统函数切片上，Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平，相对 weighted ESOP-MILP 获得 167/3/7；在 $n = 16$ 的 24 个函数上，recursive linear-pair guard 相对 root-beam 获得 23/0/1 的 score 胜/负/平，平均 score 降低 4.31%；在 $n = 18$ 的 12 个函数上，Resource-NMCTS 相对 direct ANF 平均 T-count 降低 60.05%，平均 score 降低 56.99%。这些结果支持本文方法在逻辑层低 T-count 和低加权资源上的优势，但不支持 CNOT-only 全局最优、硬件映射最优或任意函数规模下的完备最优性主张。

关键词：量子 oracle 综合；布尔函数综合；神经蒙特卡洛树搜索；ANF；FPRM；T-count；资源约束

1 引言

布尔 oracle 是 Grover 搜索、量子密码分析和许多量子算法原语中的核心组成部分。给定布尔函数 $f : \{0, 1\}^n \rightarrow \{0, 1\}$ ，标准 oracle 形式为

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle. \quad (1)$$

从经典布尔函数到可逆量子线路的转换并不只是语义保持问题。对于容错量子计算，T 门等非 Clifford 资源通常比 Clifford 门更昂贵；对于逻辑层综合，CNOT、深度、总门数和辅助比特也会影响后续映射、调度和误差校正开销。因此，一个可用的 oracle 综合方法必须同时报告正确性和资源剖面，而不能只给出布尔函数被实现这一事实。

直接基于代数正规形（algebraic normal form, ANF）的综合方法透明且容易验证。其基本做法是把每个 ANF 单项式翻译为受控乘法结构，再异或到输出位。然而，当函数包含大量高次数单项式时，direct ANF 会产生较高 T-count 和较长线路。Xor-And-Inverter Graphs (XAG) 和

乘法复杂度工作强调 XOR 结构与 AND 节点数量对低 T-count oracle 的重要性 [1, 3]。ROS 将 oracle 综合放入资源约束 LUT 映射框架 [2]。BDD synthesis 为大函数提供了另一种可扩展表示 [5]。SSHR 则用 parallelotope 空间结构面向小规模布尔函数降低 CNOT[4]。这些方向各有优势，但它们并未直接回答本文关心的问题：如果只在逻辑层考虑资源，能否把 ANF/FPRM 表示上的可复用因子结构作为搜索空间，并通过神经搜索得到稳定优于现有基线的候选线路？

本文围绕这一问题提出 Resource-NMCTS。方法不使用 SSHR 的 parallelotope 候选结构，而是在 ANF 与固定极性 Reed-Muller (fixed-polarity Reed-Muller, FPRM) 项集合上搜索 compute/uncompute 因子分解。搜索目标为统一的逻辑层资源分数：

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (2)$$

该分数用于在候选线路之间做多资源折中，不等同于某个具体硬件平台的物理代价。所有内部候选均通过 classical truth-table simulation 验证 oracle 语义。本文的核心主张也相应限定为：在逻辑层、给定资源分数和当前 benchmark 下，Resource-NMCTS 能够显著降低 T-count 与加权资源；本文不主张硬件 mapping 后仍保持同等排序。

2 相关工作

2.1 布尔表示驱动的 oracle 综合

XAG 通过把 XOR 与 AND 结构分离，为低 T-count oracle 提供了自然表示。Meuli 等人指出，XAG 中 AND 节点数量与非 Clifford 代价密切相关 [1]；乘法复杂度视角进一步说明，减少非线性乘法结构是降低 T-count 的关键路径 [3]。ROS 将 oracle synthesis 作为 resource-constrained LUT mapping 和层次化综合问题处理 [2]。这些工作与本文的共同点是都把布尔表示作为量子 oracle 成本的源头；区别是本文不以 XAG 或 LUT 为唯一中间表示，而是在 ANF/FPRM 项集合上直接搜索可复用因子。

BDD-based reversible synthesis 使用决策图分解大规模布尔函数，适合作为可扩展性 baseline[5]。近期 back-end-aware oracle synthesis 进一步把 oracle 综合连接到后端感知的 T-count、逻辑时间步和辅助比特指标 [6]。本文目前只处理逻辑层资源估计，因此与 back-end-aware 工作互补，而不是替代。

2.2 SSHR 与 small-scale Boolean synthesis

Zheng 等人的 SSHR 方法利用 parallelotope 空间结构进行 small-scale Boolean function synthesis，重点优化 CNOT 指标 [4]。本文使用 SSHR-H/SSHR-I 作为比较对象，但方法本身不沿用 parallelotope cover 搜索空间。这一区分很重要：如果把本文结果写成“SSHR 的 AI 改进版”，会削弱主张的独立性；更准确的定位是，本文把 oracle 综合重新表述为 ANF/FPRM 因子搜索，并在 T-count 与加权资源口径下与 SSHR 及其他 baseline 对比。

2.3 AI 搜索与量子线路综合

强化学习和 MCTS 已用于多个线路综合场景。ShortCircuit 使用 AlphaZero 风格搜索生成经典布尔电路 [7]；Gumbel AlphaZero 已用于 Clifford+T unitary synthesis[8]；ZX-calculus 优化中

也出现了基于 PPO 和图神经网络的 rewrite-rule 选择 [9]; MonteQ 使用 MCTS 处理特定量子线路合成中的动作排序 [10]。这些工作说明学习式搜索适合处理离散综合空间, 但它们大多不是从布尔函数直接生成 oracle。本文的差异在于把学习和 MCTS 放入 ANF/FPRM 因子分解状态空间, 并把资源向量作为候选选择的直接目标。

3 方法

3.1 问题定义与正确性验证

输入为 n 变量布尔函数 f 。实验中函数以 truth table、ANF 项集合或预定义 benchmark 的形式给出。输出为一个逻辑层 reversible oracle 线路, 要求对所有 x 满足输出位翻转 $f(x)$ 。本文对所有候选线路做 exhaustive truth-table simulation; 高维随机 ANF 函数也通过同一 oracle 验证路径检查。资源统计包括 T-count、CNOT、逻辑深度、总门数和 peak ancilla。因为不考虑硬件耦合图, depth 只表示逻辑层调度估计。

3.2 ANF/FPRM 因子分解

ANF 可写为

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i. \quad (3)$$

若多个单项式共享公共因子 $g(x)$, 可以先计算 g 到辅助比特, 再把剩余子项异或到输出, 最后 uncompute g 。这种 compute/uncompute 因子分解可能用少量辅助比特换取显著 T-count 降低。FPRM 极性搜索允许对输入变量采用固定极性翻转, 从而改变项集合形状; 同一函数在不同 polarity 下可能暴露不同公共因子。

本文还加入 linear-pair 因子。若若干项可由 $(x_i \oplus x_j \oplus \dots) \cdot h(x)$ 表示, 则线性部分只需 CNOT 计算, 而非额外 T 门。这类因子对高维随机 ANF 尤其重要, 因为高维函数中大量项之间存在局部线性关系。recursive linear-pair guard 在子问题中继续尝试该结构, 而 shallow linear-pair guard 只在较浅层使用它。

3.3 神经 MCTS 与 portfolio 选择

搜索状态为当前尚未综合的项集合, 动作为选择一个候选因子并递归处理剩余项。神经动作先验根据项数、平均次数、覆盖率、候选因子大小、即时资源收益等特征给动作评分。MCTS 使用该先验引导 rollout, 在固定预算内探索不同因子组合。由于单一搜索器可能在某些函数族上退化, 本文采用 resource-aware portfolio: direct ANF、AND-direct ANF、FPRM greedy、root-beam、linear-pair、affine greedy、Affine-NMCTS、ESOP cube beam、Resource-NMCTS 和 Pareto-Resource-NMCTS 等候选被共同生成, 并按式 (2) 选择最优正确线路。

Pareto archive 的作用是保留不同资源维度上的非支配候选。在小规模函数上, 它能在不损失 score 的情况下提供额外候选; 在高维函数上, 为控制运行时间, Resource/Profile/Pareto 有时会退化为同一个稳定 guard。因此, 本文把高维 Pareto 结果写作“可扩展 guard 证据”, 而不是写成独立 Pareto archive 的强优势证据。

3.4 高维 guard 与边界

高维随机 ANF 会带来两类问题：候选极性空间快速膨胀，以及递归因子搜索出现长尾。本文为 $n = 14, 15, 16, 18$ 分别设置 bounded guard：限制 FPRM polarity、限制候选宽度、限制递归深度，并在 $n = 18$ 使用 fast linear-pair guard。这样的设计牺牲了全局搜索完备性，但换取可复现运行时间和完整 truth-table 验证。高维结果因此是压力测试和规模证据，不是全局最优性证明。

4 实验设置

4.1 benchmark 与 baseline

实验覆盖四类数据。第一类是 $n \leq 6$ 的 177 个传统函数，用于与 direct ANF、AND-direct ANF、固定坐标 MCTS、ESOP cube beam、ESOP-MILP、SSHR-H 和外部 ABC/BDD/SSHR 结果比较。第二类是大规模核心集合，用于检查方法在 $n = 8$ 到 $n = 12$ 上的表现。第三类是高维随机 ANF 压力测试，包括 $n = 14$ 的 64 个函数、 $n = 15$ 的 32 个函数、 $n = 16$ 的 24 个函数和 $n = 18$ 的 12 个函数。第四类是小规模精确参照，包括 $n \leq 4$ 的 exact FPRM-DP 和 exact XAG 乘法复杂度下界。

外部 baseline 包括 ABC-AIG、ABC-XAG、ABC-LUT、BDD/Shannon、ABC-ESOP 和 SSHR-I。SSHR-I 在较大规模上受 ILP 时间限制，因此只在可运行切片中作为参照。所有外部结果都需要通过导出 manifest 或 truth-table 验证后才纳入分析。

4.2 资源指标

本文同时报告 T-count、CNOT、depth、peak ancilla 和 score。T-count 是主要优化目标，因为它对应 logical-AND 模型中的非 Clifford 开销；CNOT 和 depth 用于揭示 trade-off；peak ancilla 用于衡量中间计算空间。score 用于比较多资源候选，但不应替代单项指标解读。

5 结果

5.1 传统函数切片

表 1 总结 $n \leq 6$ 的传统函数切片。相对 direct ANF, Pareto-Resource-NMCTS 平均 T-count 从 184.1 降至 40.4, 平均 score 从 194.3 降至 49.6。相对 ESOP cube beam, Pareto-Resource-NMCTS 的 score 胜/负/平为 174/0/3, 平均 score 降低 36.09%；相对 weighted ESOP-MILP, score 胜/负/平为 167/3/7, 平均 score 降低 29.84%。SSHR-H 的平均 CNOT 为 67.6, 低于 Pareto-Resource-NMCTS 的 83.0, 因此本文不能宣称 CNOT-only 支配；但 Pareto-Resource-NMCTS 在 T-count 和加权 score 上更强。

5.2 搜索贡献分解

搜索消融显示，提升不是由单个启发式偶然造成的。Affine greedy 相对固定坐标 MCTS 的 score 改善为 165/88/68, 平均 score 降低 12.12%；neural refine over affine greedy 的 score 改善为 65/0/257, 平均 score 降低 1.08%；guarded Affine-NMCTS over no-guard 的 score 改善为 88/0/234, 平均 score 降低 1.74%；Pareto-Resource-NMCTS over Resource-NMCTS 的 score 改善

表 1: $n \leq 6$ 传统函数切片上的平均逻辑资源。

方法	平均 T	平均 CNOT	平均深度	平均 ancilla	平均 score
Direct ANF	184.1	134.2	134.6	1.33	194.3
AND-direct ANF	101.0	166.5	166.9	2.18	115.2
Fixed MCTS	62.1	124.3	124.8	1.82	73.1
Affine-NMCTS	45.9	94.4	98.9	1.88	55.4
Resource-NMCTS	43.9	89.9	94.5	1.92	53.2
Pareto-Resource-NMCTS	40.4	83.0	88.0	2.03	49.6
ESOP-MILP	83.6	133.5	159.6	2.32	96.7
SSHR-H	81.0	67.6	88.7	1.36	88.2

表 2: 高维随机 ANF 压力测试中的主要比较。

规模	对比	函数数	score 胜/负/平	平均 T 变化	平均 score 变化
$n = 14$	linear-pair guard vs root-beam	64	60/0/4	-4.19%	-3.00%
$n = 15$	recursive guard vs root-beam	32	30/0/2	-6.43%	-5.28%
$n = 16$	recursive guard vs shallow guard	24	23/0/1	-2.62%	-2.54%
$n = 16$	recursive guard vs root-beam	24	23/0/1	-4.64%	-4.31%
$n = 18$	fast guard vs root-beam	12	6/0/6	-2.72%	-1.91%
$n = 18$	Resource-NMCTS vs fast guard	12	12/0/0	-3.75%	-3.55%

为 68/0/109, 平均 score 降低 3.26%。这说明仿射坐标搜索是主要前置收益, 神经 refine 和 guard 提供小幅但无 score loss 的增益, Pareto archive 则在小规模函数上提供明确的 portfolio 改善。

5.3 高维随机 ANF 压力测试

表 2 给出 $n = 16$ 和 $n = 18$ 的关键结果。 $n = 16$ 新增 recursive linear-pair guard 后, 24 个函数全部完成, 0 error、0 skipped。相对 shallow linear-pair guard, recursive guard 的 score 胜/负/平为 23/0/1, 平均 score 降低 2.54%; 相对 root-beam, score 胜/负/平为 23/0/1, 平均 score 降低 4.31%。由于 Resource-NMCTS、Profile-Resource-NMCTS 和 Pareto-Resource-NMCTS 在该设置下都选择同一 deep guard, 高维 $n = 16$ 结果应写成 recursive guard 的正向证据, 而不是独立 Pareto archive 证据。

从 direct ANF 角度看, 高维压力测试的降幅更明显。 $n = 16$ 上 Resource-NMCTS 平均 T-count 从 12053.7 降至 3700.3, 平均 score 从 12369.5 降至 4084.0; 相对 direct ANF 的平均 T 降幅为 63.34%, 平均 score 降幅为 60.81%。 $n = 18$ 上 Resource-NMCTS 相对 direct ANF 平均 T 降低 60.05%, 平均 score 降低 56.99%。代价是 CNOT、depth 和 peak ancilla 相对 direct ANF 经常升高, 因此这些结果支持低 T 和低 score, 而不是所有资源维度同时下降。

5.4 精确小规模参照

exact FPRM-DP 切片在 $n \leq 4$ 的 72 个函数上枚举 bounded fixed-polarity FPRM factor model 中的所有单项式因子和 linear-pair 因子。结果显示, Resource-NMCTS 相对 exact FPRM-DP 的 score 胜/负/平为 51/3/18, Pareto-Resource-NMCTS 为 51/0/21。这说明当前 portfolio 可

以找到受限 FPRM-DP 模型之外的更优候选，而不是只依赖一个未求尽的启发式求解器。

exact XAG 乘法复杂度切片提供更硬的 T-count 参照。在 $n \leq 4$ 的 72 个函数上，exact BFS 求得最少 AND 节点数， $4 \times \text{minAND}$ 构成 logical-AND 模型下的 T-count 下界。Resource-NMCTS 和 Pareto-Resource-NMCTS 在 12/72 个函数上达到该下界，平均 T gap 为 +53.01%；ESOP-MILP 的平均 T gap 为 +120.14%，SSHR-I-T 为 +143.06%。这支持 Resource-NMCTS 更接近小规模乘法复杂度下界，但不等于完整 reversible circuit 全局最优。

6 讨论

当前结果说明，ANF/FPRM 因子分解是一个有价值的 oracle 综合搜索空间。相对 direct ANF，它通过公共因子、线性因子和 compute/uncompute 复用显著降低 T-count；相对 ESOP 和 SSHR，它把优化重点从单一表示或 CNOT-only 目标转向多资源候选选择。更重要的是，搜索贡献分解显示提升来自多个可解释模块：仿射坐标变换提供最大前置收益，神经 refine 与 guard 提供稳定增益，Pareto archive 在小规模函数上扩展候选集合，高维 linear-pair guard 则让方法能在 $n = 14$ 到 $n = 18$ 压力测试中保持可运行。

本文也存在明确边界。第一，高维 learned prior 目前不是强正向证据；在 $n = 14$ 小切片上，专用 high-dimensional prior 只带来 1/0/11 的 score 胜/负/平，平均 score 变化约为 -0.01%，且运行时间增加。因此，若要强调 AI 贡献，应主要依赖小规模 learned prior、neural refine 和 MCTS/Pareto 搜索，而不能夸大高维神经排序。第二，CNOT 与 depth 并非总是下降，尤其相对 SSHR-H 或 direct ANF 时会出现 trade-off。第三，外部 toolchain 仍不完整；ABC 和 BDD 结果已经纳入，但 ROS、RevKit 或 mockturtle 风格的可复现 reversible-toolchain 对比仍需要补强。第四，当前资源模型是逻辑层模型，未加入硬件连通性、routing、真实噪声和容错调度。

这些边界并不否定当前主张，但决定了论文应如何表述。更稳妥的投稿定位是“面向逻辑层资源约束的神经搜索式 Boolean oracle synthesis”，而不是“硬件感知量子编译”或“全局最优 oracle synthesis”。若后续要达到更强发表标准，应优先补充可复现外部 oracle synthesis 工具链对比、高维 root-action teacher 训练、不同 score 权重下的鲁棒性分析，以及代表性函数族上的线路结构案例。

7 结论

本文提出 Resource-NMCTS，把量子布尔函数 oracle 综合建模为 ANF/FPRM 因子分解上的资源约束搜索问题，并结合神经先验、MCTS、仿射坐标搜索、linear-pair guard 和 Pareto archive 生成逻辑层候选线路。当前实验证明，该方法在 $n \leq 6$ 传统函数上相对 ESOP、direct ANF、固定坐标 MCTS 和多个外部 baseline 具有显著低 T-count 与低 score 优势；在 $n = 16$ 和 $n = 18$ 高维随机 ANF 上，recursive/fast linear-pair guard 提供可验证的规模扩展证据；在 exact FPRM-DP 和 exact XAG 小规模切片上，结果进一步说明方法并非仅优于弱启发式 baseline。论文的结论应严格限定在逻辑层资源综合，不包含硬件映射最优性。下一步需要补齐更强外部工具链、训练可解释的高维 root-action ranker，并用更多权重设置和函数族验证方法的稳健性。

参考文献

- [1] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.
- [2] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained Oracle Synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.
- [3] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.
- [4] J. Zheng, X. Xu, Y. Zhang, Y. Su, and X. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. *arXiv preprint*, 2025.
- [5] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, 2009.
- [6] Y. Yu, C. Tempia Calvino, M. Soeken, and G. De Micheli. Back-end-aware fault-tolerant quantum oracle synthesis. In *Proceedings of ASP-DAC*, 2025.
- [7] K. Tsaras et al. ShortCircuit: AlphaZero-driven circuit design. *arXiv preprint arXiv:2408.09858*, 2024.
- [8] S. Rietsch et al. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *Proceedings of IEEE QCE*, 2024.
- [9] M. Riu, M. Nogue, V. Vilaplana, A. Garcia-Saez, and M. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [10] H. Machiya, M. Menickelly, P. Hovland, and Y. Liu. MonteQ: A Monte Carlo Tree Search based quantum circuit synthesis framework. *arXiv preprint*, 2026.