

基于强化学习与蒙特卡洛树搜索的资源约束量子布尔函数综合方法

中文论文稿 v12: 投稿框架与证据边界版

2026 年 7 月 8 日

摘要

量子布尔函数 oracle 综合是把经典谓词接入量子算法的核心编译步骤。传统综合路线通常在布尔表示、可逆逻辑分解或 CNOT 导向覆盖空间中优化单一资源，但容错量子计算中的实际逻辑开销同时受 T-count、CNOT、深度、总门数和辅助比特影响。本文将 oracle 综合表述为代数正规形 (algebraic normal form, ANF) 与固定极性 Reed-Muller (fixed-polarity Reed-Muller, FPRM) 项集合上的资源约束搜索问题，提出结合神经动作先验、蒙特卡洛树搜索、布尔环线性因子筛选、结构级 depth policy 和保守 guard 的 Resource-NMCTS 框架。与 SSHR 不同，本文方法不枚举 parallelotope cover; SSHR 仅作为 small-scale CNOT-oriented baseline。实验表明，在 $n \leq 6$ 的 177 个传统函数上，Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平，平均 score 降低 36.09%；相对 weighted ESOP-MILP 获得 167/3/7，平均 score 降低 29.84%。在 $n = 18$ 的随机 ANF 函数上，完整 Resource-NMCTS 相对 adaptive depth-2 Boolean-ring screen 进一步降低 23.85% 平均 score；在 $n = 20$ 边界函数上，screen-gated Resource-NMCTS 与完整 Resource-NMCTS 资源持平并把平均运行时间从 77.10 s 降至 20.71 s。在 $n = 20, 22, 24, 28, 32, 36, 40$ 的项集级 scale 测试中，depth policy 相对 single screen 稳定降低 5.55%–6.56% 平均 score，并相对 all-depth adaptive 节省约三分之一时间。进一步的 depth-frontier 实验显示，depth-4 Boolean-ring screen 相对 fixed depth-2 在 $n = 20, 28, 40$ 上平均 score 再降低 3.10%，说明更深结构筛选形成了新的质量前沿。所有 3000 个项集级方法行均通过 factor-plan ANF 展开验证和 emitted X/CNOT/MCT circuit 的 GF(2) 多项式符号模拟验证。本文的阶段性结论是：该路线已经形成独立于 SSHR 的逻辑层低 T-count/低加权资源综合主线，但最终投稿仍需补充更强的高维学习策略收益、完整 truth-table 可验证桥接实验和外部工具链对比。

关键词：量子 oracle 综合；布尔函数综合；强化学习；蒙特卡洛树搜索；ANF；FPRM；布尔环；资源约束综合

1 引言

给定布尔函数 $f : \{0, 1\}^n \rightarrow \{0, 1\}$ ，量子 oracle 通常实现为

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle. \quad (1)$$

这类 oracle 出现在 Grover 搜索、密码分析、约束满足、组合优化和若干量子算法子程序中。若 f 的综合线路被直接展开为单项式逐项写入输出位，语义验证简单，但会丢失可共享的代数结构；若

只优化 CNOT 或只压缩 AND 节点，又可能增加 T 门、辅助比特或调度深度。因此，本文把量子布尔函数综合视为一个多资源组合搜索问题，而不是单一门数最小化问题。

本文采用 ANF 作为基础表示：

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i. \quad (2)$$

ANF 的优势是语义透明，任一项都能映射为受控乘法结构；缺点是原始项集合不显式给出公共因子、线性奇偶量、极性重写和可递归分解的子问题。已有 XAG、ROS、BDD 与 SSHR 等工作从不同中间表示改进 oracle 或可逆逻辑综合 [2, 3, 4, 6]。这些方法说明表示选择会显著影响资源，但并未直接回答一个问题：能否在 ANF/FPRM 项集合上定义可搜索的代数动作，并用 AI 策略选择更有资源收益的综合路径？

本文的一句话论证是：在逻辑层量子布尔函数 oracle 综合中，ANF/FPRM 项集合上的资源感知神经搜索，配合布尔环线性因子筛选和保守结构门控，可以在传统函数与高维项集合上降低 T-count 和加权逻辑资源；当前边界是该方法尚未覆盖硬件 mapping、真实噪声模型和完整的大规模 truth-table 枚举验证。这个表述也决定了本文和 SSHR 的关系：SSHR 是 CNOT-oriented small-scale baseline，而不是本文方法的出发点。

2 相关工作与定位

2.1 布尔表示驱动的 oracle 综合

Xor-And-Inverter Graphs (XAG) 将 XOR 与 AND 结构分离，使 AND 节点数量与非 Clifford 成本直接相关。Meuli 等人将 XAG 用于 quantum compilation[2]，并从 multiplicative complexity 角度讨论低 T-count oracle 的结构来源 [1]。ROS 进一步把 oracle synthesis 写成 resource-constrained LUT mapping[3]。本文与这些工作共同强调布尔结构对逻辑资源的决定作用，但本文不固定使用 XAG 或 LUT，而是在 ANF/FPRM 项集合上搜索可计算、可反算的因子结构。

BDD-based reversible synthesis 可以处理较大的布尔函数 [4]。Back-end-aware oracle synthesis 则把 XAG 优化与后端质量指标连接起来 [5]。这些工作覆盖了本文尚未完成的后端维度。本文当前只报告逻辑层 T-count、CNOT、depth、gate count 和 peak ancilla，不包含 routing、magic-state factory、连通性约束或噪声下保真度。

SSHR 使用 parallelotope 的空间结构做 small-scale Boolean function 的 CNOT-oriented synthesis[6]。本文保留 SSHR-H/SSHR-I 作为比较对象，但不继承其 candidate 空间。更准确地说，本文是一条面向低 T-count 和加权逻辑资源的项集合搜索路线，SSHR 在这里只用于说明 CNOT 指标上的 trade-off。

2.2 学习式搜索与线路优化

学习式搜索已经用于多个离散综合任务。ShortCircuit 采用 AlphaZero 风格搜索设计经典布尔电路 [7]；Gumbel AlphaZero 被用于 Clifford+T unitary synthesis[8]；ZX-calculus 优化中出现了强化学习和图神经网络驱动的 rewrite-rule 选择 [9]；MonteQ 使用 MCTS 处理量子线路综合的动作排序 [10]。这些工作说明，学习策略适合处理组合动作空间。本文的差异在于状态、动作和奖励

表 1: 本文的核心术语与边界。

术语	本文含义
Resource-NMCTS	在 ANF/FPRM 项集合上进行资源加权搜索的主框架, 包括神经先验、MCTS、guard 和 portfolio 选择。
Boolean-ring screen	在 square-free Boolean ring 中搜索可复用线性因子的结构筛选分支, 允许线性因子与 quotient 共享变量。
Depth policy	预测 single、depth-1 或 depth-2 screen 的结构级神经策略。
Depth-frontier	使用 depth-3/4 Boolean-ring screen 追求更低 score 的高预算质量模式。
SSHR	CNOT-oriented small-scale baseline; 本文方法不从 SSHR 搜索空间出发。

都围绕 Boolean oracle 的 ANF/FPRM 因子分解定义, AI 模块主要承担动作排序、结构深度选择和安全门控, 而不是直接生成任意量子门序列。

3 问题定义与资源模型

本文输入为布尔函数的 truth-table 或 ANF 表示, 输出为实现式 (1) 的逻辑层可逆线路。候选线路由 X、CNOT 和多控 Toffoli (MCT) 抽象门组成, 并在资源统计阶段转化为 T-count、CNOT、深度、总 gate count 和 peak ancilla。用于搜索排序的统一分数定义为

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (3)$$

该分数用于比较候选逻辑线路, 不代表某个具体设备的物理时间或错误率。为避免单一分数掩盖 trade-off, 实验同时报告 T-count、CNOT、depth、gate count 和 peak ancilla。

在 $n \leq 20$ 的函数级实验中, 候选线路通过完整 truth-table 语义验证。在 $n > 20$ 的项集级 scale 实验中, 完整 truth-table 构造本身不可接受, 因此采用两层符号验证: 第一层将 factor plan 展开回 ANF 项集合, 检查目标项集合等价; 第二层对 emitted X/CNOT/MCT circuit 做 GF(2) 多项式符号模拟, 检查输入线复原、输出线等价和辅助线清零。该验证不等同于逐点枚举 2^n 个输入, 但强于只统计 plan 资源。

4 方法

4.1 状态、动作与搜索流程

Resource-NMCTS 的状态是当前尚未综合的项集合 $\mathcal{M}$ 。一次动作选择一个可计算、可反算的局部代数结构, 将 $\mathcal{M}$ 分解为 quotient 子问题和 rest 子问题, 再递归生成 compute/action/uncompute 形式的线路。候选动作包括公共单项式因子、FPRM 极性重写后的公共项、线性奇偶因子、布尔环线性因子, 以及由神经模型扩展的 root actions。

神经动作先验不直接输出量子门序列, 而是对候选因子动作排序。特征包括候选覆盖率、项数变化、项平均次数、变量覆盖密度、即时资源收益和子问题规模等结构统计。MCTS 在有限预算内探索候选组合, rollout 使用确定性资源估计与已有 baseline 候选。最终选择由 baseline-preserving

guard 兜底：若学习候选不优于确定性 baseline，则返回 baseline。这个设计牺牲部分探索自由度，但降低了学习模型在分布外项集上造成资源退化的风险。

4.2 布尔环线性因子筛选

早期 linear-pair 分支主要搜索

$$(x_i \oplus x_j \oplus \dots) \cdot h(x) \quad (4)$$

形式的结构，并要求线性因子变量与 quotient $h(x)$ 的变量不相交。该约束便于实现，却排除了 square-free Boolean ring 中合法的重叠变量情形。本文的 Boolean-ring screen 允许二者共享变量，并在展开时使用 $x_i^2 = x_i$ 与 GF(2) 偶数项消去。例如

$$(x_i \oplus x_j)x_im = x_im \oplus x_ix_jm. \quad (5)$$

线路层面仍可先用 CNOT 计算线性奇偶量，再用该辅助量控制 quotient 子线路。因此，布尔环线性因子不是简单扩大 beam 宽度，而是把原先被实现约束排除的代数候选重新纳入可综合搜索空间。

4.3 结构级 AI 与保守门控

高维实验显示，single screen、depth-1 screen 和 depth-2 screen 的收益依赖项集结构。本文因此训练 depth policy，输入项数、次数分布、变量覆盖密度、二元共现密度和 root Boolean-ring action 统计，输出应该使用的 screen 深度。监督标签来自实际运行三种 screen 后按式 (3) 选择的最佳 depth。

固定 depth-2 screen 是强质量 baseline，因此本文又训练保守 depth-2 skip guard。Static-direct 模式只使用项集合静态特征，若预测 depth-1 足以与 fixed depth-2 持平，则直接运行较浅 screen；否则运行 depth-2。阈值按 zero-false-skip 约束选择，使门控优先避免质量损失。类似地， $n = 20$ 边界切片中完整 Resource tail 与 adaptive screen 资源持平但运行更慢，本文训练 screen-gate 判断是否可以跳过 Resource tail。当前 screen-gate 只作为运行时控制证据，不作为高维质量提升的主证据。

5 实验设计

实验分为五组。第一组使用 $n \leq 6$ 的 177 个传统函数，与 direct ANF、AND-direct ANF、ESOP cube beam、weighted ESOP-MILP、SSHR-H、ABC 和 BDD baseline 比较。第二组使用 $n = 18$ 随机 ANF 函数，观察 adaptive screen 与完整 Resource-NMCTS 的差距。第三组使用 $n = 20$ 边界函数，检验在 FPRM root beam 和 fast linear-pair 超时区域中，depth-2 screen 是否仍能给出可运行改进，并用 $n = 19, 20$ held-out 切片验证 screen-gate 是否会错误跳过 Resource tail。第四组使用 $n = 14, 16, 18$ 生成式项集训练 depth policy 与 skip guard，并在 held-out $n = 20$ 项集上测试结构选择能力。第五组在 ANF 项集上评估 $n = 20, 22, 24, 28, 32, 36, 40$ 的 scale 行为，并对每个 plan 和 emitted circuit 做符号等价验证。

表 2: $n \leq 6$ 传统函数切片上的平均逻辑资源。

方法	平均 T	平均 CNOT	平均 depth	平均 ancilla	平均 score
Direct ANF	184.1	134.2	134.6	1.33	194.3
AND-direct ANF	101.0	166.5	166.9	2.18	115.2
Resource-NMCTS	43.9	89.9	94.5	1.92	53.2
Pareto-Resource-NMCTS	40.4	83.0	88.0	2.03	49.6
ESOP-MILP	83.6	133.5	159.6	2.32	96.7
SSHR-H	81.0	67.6	88.7	1.36	88.2

所有 paired comparison 只纳入函数名或项集名匹配、语义正确且未 timeout 的结果。Timeout 行保留为运行边界证据，但不参与正确结果均值比较。本文所有实验均为逻辑层资源估计，不包含 hardware mapping 和 noise-aware scheduling。

6 结果

6.1 小规模传统函数

表 2 给出 $n \leq 6$ 传统函数上的平均逻辑资源。相对 direct ANF, Pareto-Resource-NMCTS 平均 T-count 降低 72.25%，平均 score 降低 67.80%。相对 ESOP cube beam, Pareto-Resource-NMCTS 获得 174/0/3 的 score 胜/负/平，平均 score 降低 36.09%。相对 weighted ESOP-MILP, 获得 167/3/7，平均 score 降低 29.84%。

该结果支持本文的低 T-count 与加权资源优势，但也给出重要边界：SSHR-H 的平均 CNOT 最低，因此本文不能主张 CNOT-only 指标全面支配 SSHR。更准确的结论是，本文方法在当前资源权重下用一定 CNOT 与辅助比特 trade-off 换取更低 T-count 和更低 score。

6.2 高维函数级边界

在 $n = 18$ 的 12 个随机 ANF 函数上，adaptive depth-2 Boolean-ring screen 相对 single screen 获得 11/0/1 的 score 胜/负/平，平均 score 从 11349.06 降至 10670.94；完整 Resource-NMCTS 平均 score 为 7315.62，相对 adaptive screen 进一步降低 23.85%。这说明 $n = 18$ 上快速 screen 是有效候选生成器，但不能替代完整资源搜索。

在 $n = 20$ 边界函数上，FPRM root beam 和 fast linear-pair 均触发 300 s task timeout。Adaptive depth-2 screen 相对 single screen 获得 5/0/1，平均 score 降低 7.47%。集成该分支后，Resource-NMCTS 相对 AND-direct ANF 获得 5/0/1，平均 score 降低 11.80%。由于此切片中完整 Resource tail 与 adaptive screen 资源持平，screen-gated Resource-NMCTS 可以把平均时间从 77.10 s 降到 20.71 s。

表 3: 高维函数级边界结果。

切片	方法	平均 T	平均 CNOT	平均 score	平均时间 (s)
$n = 18$	Single screen	10389.33	16268.42	11349.06	0.82
$n = 18$	Adaptive depth-2 screen	9767.00	15301.58	10670.94	4.39
$n = 18$	Resource-NMCTS	6639.33	11380.92	7315.62	226.18
$n = 20$	AND-direct ANF	21516.67	33635.67	23491.15	10.41
$n = 20$	Single screen	20786.00	32492.50	22695.15	10.70
$n = 20$	Adaptive depth-2 screen	19535.33	30542.50	21331.24	20.67
$n = 20$	Resource-NMCTS	19535.33	30542.50	21331.24	77.10
$n = 20$	Screen-gated Resource-NMCTS	19535.33	30542.50	21331.24	20.71

6.3 结构级 AI 结果

Depth policy 在 $n = 14, 16, 18$ 项集上训练, 并在 held-out $n = 20$ 项集上评估。Policy 相对 single screen 获得 42/0/6, 平均 score 降低 6.57%; 相对 depth-1 screen 获得 34/0/14, 平均 score 降低 2.57%。相对 all-depth adaptive, policy 平均 score 只高 0.28%, 但平均运行时间降低 34.71%。这说明结构级 AI 已能学习 screen 深度选择, 但尚未在 score 上超过 fixed depth-2。

保守 depth-2 skip guard 去掉了这一质量缺口。Static-direct 模式在 held-out $n = 20$ test 中没有 false skip, 96 个样本全部与 fixed depth-2 screen score 持平, 并相对 fixed depth-2 与 all-depth adaptive 分别节省 0.54% 和 24.74% 平均时间。Screen-gate 的独立 held-out 验证也支持保守门控: 在 $n = 19, 20$ 共 16 个函数上, screen-gated Resource-NMCTS 与完整 Resource-NMCTS 全部 score 持平, 平均节省 36.83% 时间; 若直接用 adaptive screen 替代 Resource tail, $n = 19$ 子集会出现 4/8 个 score loss。

6.4 项集级 scale 与 depth-frontier

表 4 汇总 $n = 20, 22, 24, 28, 32, 36, 40$ 的项集级结果。在 $n = 20, 22, 24, 28$ 上, depth policy 相对 single screen 获得 169/0/23, 平均 score 降低 6.56%; 相对 all-depth adaptive 只有 0/6/186, 平均 score 增加 0.08%, 但平均时间降低 31.01%。在 $n = 32, 36, 40$ 上, depth policy 相对 single screen 获得 110/0/34, 平均 score 降低 5.55%; 相对 all-depth adaptive 在 144 个项集上全部 score 持平, 并节省 33.14% 平均时间。

表 4: 项集级 screen-scale 结果。所有方法行均通过 plan 和 emitted-circuit ANF 符号验证。

范围	方法	baseline	score 胜/负/平	平均 Δ score	平均 Δ time
20-28	adaptive all-depth	single screen	169/0/23	-6.63%	+3077.71%
20-28	depth policy	single screen	169/0/23	-6.56%	+2328.66%
20-28	depth policy	all-depth adaptive	0/6/186	+0.08%	-31.01%
32-40	adaptive all-depth	single screen	110/0/34	-5.55%	+2680.60%
32-40	depth policy	single screen	110/0/34	-5.55%	+2061.11%
32-40	depth policy	all-depth adaptive	0/0/144	+0.00%	-33.14%

前述策略偏向快速或中等预算。为判断 fixed depth-2 是否已经达到质量上限, 本文又在 $n = 20, 28, 40$ 的 72 个项集上运行 depth-3/4 Boolean-ring screen。表 5 显示, depth-3 相对 fixed depth-2 获得 49/0/23, 平均 score 降低 1.93%; depth-4 相对 fixed depth-2 同样获得 49/0/23, 平均 score 降

低 3.10%。这说明更深布尔环筛选确实能形成新的质量前沿，但代价是运行时间分别增加 193.71% 和 682.97%。因此，depth-3/4 应被写成高预算质量模式，而不是默认快速策略。

表 5: $n = 20, 28, 40$ depth-frontier screen-scale 比较。

方法	baseline	score 胜/负/平	平均 Δ score	平均 Δ time
screen depth-3	fixed depth-2	49/0/23	-1.93%	+193.71%
screen depth-4	fixed depth-2	49/0/23	-3.10%	+682.97%
screen depth-4	screen depth-3	44/0/28	-1.21%	+127.55%
all-depth adaptive depth ≤ 4	fixed depth-2	49/0/23	-3.10%	+1129.85%

主 scale、extended scale 和 depth-frontier 三组项集级结果合计包含 3000 个方法行。所有方法行均通过两层验证：factor plan 的 ANF 展开验证为 3000/3000，emitted X/CNOT/MCT circuit 的 GF(2) 多项式符号模拟验证为 3000/3000，mismatch 总数为 0。这使项集级结果不只是资源估计，但仍应明确它不是完整 truth-table simulation。

7 证据地图与投稿缺口

表 6 给出当前主张和证据的对应关系。该表是 v12 与前几版的主要区别：它把哪些结论已经能写进摘要、哪些只能写进讨论区分开，避免把阶段性实验误写成最终投稿结论。

表 6: 当前可支撑主张与缺口。

主张	证据	投稿状态
独立于 SSHR 的低 T-count/低 score 主线	$n \leq 6$ 传统函数相对 ESOP、weighted ESOP-MILP 和 direct baselines 的稳定优势；SSHR-H 保留为 CNOT trade-off 参照。	可写入摘要，但需说明 CNOT-only 不支配 SSHR。
布尔环 screen 是高维有效结构筛选	$n = 18$ 、 $n = 20$ 函数级边界以及 $n = 20$ 到 $n = 40$ 项集级 scale 均显示相对 single screen 的 score 改善。	可作为核心方法贡献。
结构级 AI 能减少自适应搜索成本	Depth policy 与 skip guard 在 held-out 项集上接近或持平 all-depth adaptive，并节省约三分之一时间。	可作为 AI 贡献，但不宜夸大为强质量提升。
Depth-frontier 提供新的质量提升目标	Depth-4 相对 fixed depth-2 平均 score 再降低 3.10%，但时间增加 682.97%。	可作为最新明显提升；需要进一步学习化。
高维 emitted circuit 语义可信	3000/3000 项集级方法行通过 plan 展开和 emitted circuit GF(2) 符号模拟验证。	可支撑项集级结果，但不能替代完整 truth-table。
完整 RL/MCTS 在高维上形成强独立收益	当前高维 learned prior 独立质量收益仍弱，部分切片主要由 screen/guard 驱动。	仍是投稿前主要缺口。

下一步最直接的提升目标不是继续扩大维度，而是把 depth-frontier 的质量收益学习化：训练一个能在高预算和快速预算之间选择的结构策略，使其在 $n = 20, 28, 40$ 上接近 depth-4 质量，同时显著低于 all-depth adaptive depth ≤ 4 的时间。第二个目标是补充 $n = 21, 22$ 的完整 truth-table bridge，使“ $n > 20$ 只能符号验证”的边界向后移动。第三个目标是引入更强外部工具链对比，尤其

是 ROS、mockturtle/ABC 风格映射和 back-end-aware oracle synthesis, 使论文不只和内部 baseline 比较。

8 讨论

本文最稳妥的贡献表述有四点。第一, 方法主线独立于 SSHR。本文不是把 SSHR 改成 AI 版本, 而是在 ANF/FPRM 项集合上做资源加权搜索; SSHR 的作用是 CNOT-oriented baseline。第二, 布尔环线性因子提供了明确的结构扩展, 允许线性因子与 quotient 共享变量, 并在 $n = 18, 20$ 和项集级 scale 上稳定改善 single screen。第三, 结构级 AI 已有正向证据: depth policy 学会了 screen 深度选择, 保守 guard 消除了相对 fixed depth-2 的 score 缺口, 并减少 all-depth adaptive overhead。第四, depth-frontier 证明 fixed depth-2 不是质量上限, 后续学习策略可以围绕“接近 depth-4 质量、保留 depth-2 时间”设计。

当前结果还不能支撑更强结论。其一, $n = 18$ 上完整 Resource-NMCTS 仍能超过 adaptive screen, 说明中等高维仍需要更深搜索; 其二, $n = 20$ 切片中完整 Resource-NMCTS 与 adaptive screen 资源持平, 说明该切片收益主要来自结构筛选而非 MCTS tail; 其三, 高维 learned prior 的独立质量收益仍弱, 当前 AI 主体更多体现为结构选择和安全门控; 其四, $n = 22$ 到 $n = 40$ 的项集级结果虽有 emitted-circuit ANF 符号等价验证, 但不包含完整 truth-table 枚举。

9 结论

本文提出了面向资源约束量子布尔函数综合的 Resource-NMCTS 方法。它以 ANF/FPRM 项集合为状态, 以逻辑资源 score 为目标, 用布尔环线性因子、神经动作先验、MCTS、baseline guard、depth policy 和 screen-gate 共同生成候选线路。实验表明, 该方法在 $n \leq 6$ 传统函数上显著降低 T-count 与加权 score, 在 $n = 18, 20$ 高维函数级切片上验证了 adaptive screen 与 Resource tail 的互补作用, 在 $n = 20$ 到 $n = 40$ 项集级 scale 测试中展示了结构级 AI 的可扩展性, 并通过 depth-frontier 实验证明更深 Boolean-ring screen 可在高预算下继续降低 score。当前稿件已经形成独立于 SSHR 的论文主线, 但最终投稿还需要继续强化高维神经策略的质量收益、完整 truth-table 可验证切片和外部工具链比较。

参考文献

- [1] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.
- [2] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.
- [3] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained oracle synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.

- [4] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, pp. 270–275, 2009.
- [5] M. Yu, A. Tempia Calvino, M. Soeken, and G. De Micheli. Back-end-aware fault-tolerant quantum oracle synthesis. In *Proceedings of ASP-DAC*, pp. 930–937, 2025.
- [6] Q. Zheng, Y. Xu, J. Zhang, Z. Su, and S. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. In *Proceedings of ICCAD*, 2025.
- [7] D. Tsaras, A. Grosnit, L. Chen, Z. Xie, H. Bou-Ammar, and M. Yuan. ShortCircuit: AlphaZero-driven circuit design. *arXiv:2408.09858*, 2024.
- [8] S. Rietsch, A. Y. Dubey, C. Ufrecht, M. Periyasamy, A. Plinge, C. Mutschler, and D. D. Scherer. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *IEEE International Conference on Quantum Computing and Engineering*, pp. 824–835, 2024.
- [9] J. Riu, J. Nogu  , G. Vilaplana, A. Garcia-Saez, and M. P. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [10] M. Machiya, M. Menickelly, P. Hovland, and J. Liu. MonteQ: A Monte Carlo tree search based quantum circuit synthesis framework. *arXiv:2604.19029*, 2026.