

面向资源约束量子布尔函数综合的神经蒙特卡洛树搜索方法： 中文方案与阶段性证据稿

Resource-NMCTS 中文交付稿

2026 年 7 月 7 日

摘要

本文整理一个可继续发展为正式投稿的中文方案：将量子布尔函数 oracle 综合建模为 ANF/FPRM 项集合上的资源约束搜索问题，并以神经动作先验、蒙特卡洛树搜索、linear-pair 因子、baseline-preserving guard 和 Pareto 候选库共同生成逻辑层低资源线路。该方案不依赖 SSHR 的 parallelotope 候选空间；SSHR 只作为 CNOT-oriented small-scale baseline 参与比较。当前最强证据来自三条线：第一， $n \leq 6$ 的 177 个传统函数上，Pareto-Resource-NMCTS 相对 ESOP cube beam 获得 174/0/3 的 score 胜/负/平，平均 score 降低 36.09%；第二， $n = 16$ 的 24 个随机 ANF 函数上，baseline-preserving AI guard 相对 deterministic recursive guard 获得 6/0/18，平均 score 降低 0.05%，说明神经排序在确定性兜底下可以转化为无 score-loss 小增益；第三， $n = 18$ 的 12 个函数上，Resource-NMCTS 相对 direct ANF 平均 T-count 降低 60.05%，平均 score 降低 56.99%。新增 pairwise root-action ranker 将 $n = 14$ 高维 learned prior 结果从 1/0/11、平均 score 降低 0.01% 改进到 2/0/10、平均 score 降低 0.04%，但运行时间增加 124.91%，因此当前 AI 证据仍不足以作为目标结束点。本文建议把论文主张限定为逻辑层低 T-count 与低加权资源优势，并把下一阶段重点放在更强的高维神经排序、外部 reversible-toolchain 复现和代表性线路案例上。

关键词：量子 oracle 综合；布尔函数综合；神经蒙特卡洛树搜索；ANF；FPRM；T-count；资源约束

1 一句话论证与投稿定位

本文的一句话论证是：在逻辑层量子布尔函数 oracle 综合中，直接在 ANF/FPRM 项集合上进行资源感知因子搜索，并用神经先验与 MCTS 改善动作选择，可以在同一 benchmark 上稳定降低 T-count 与加权逻辑资源；该结论由传统函数、ESOP/ABC/BDD/SSHR baseline、高维随机 ANF 压力测试、搜索消融和小规模 exact 参照共同支撑。

这个定位刻意避开“从 SSHR 入手”。SSHR 的核心优势是 parallelotope 空间上的 CNOT-oriented synthesis，而本文方法的核心对象是 ANF/FPRM 项集合、公共因子、线性因子和 compute/uncompute 复用。两者可以比较，但不应把本文写成 SSHR 的附属版本。更稳妥的投稿标签是：resource-aware Boolean oracle synthesis、symbolic factor search、neural MCTS、logic-level quantum compilation。

表 1 锁定本文后续写作中的主要术语。

表 1: 术语锁定。

术语	本文含义	写作决策
Resource-NMCTS	面向 ANF/FPRM 项集合的资源约束神经 MCTS/portfolio 综合器	全文使用该名, 不写成 AI-SSHR
Pareto-Resource-NMCTS	在小规模切片中保留多资源非支配候选的 portfolio 变体	高维中若退化为稳定 guard, 需明确说明
SSHR	paralleloptope 空间上的 CNOT-oriented baseline	作为比较对象, 不作为本文内部搜索空间
AI guard	deterministic guard 与 neural guard 并行运行后取更低 score 的保守策略	写成无 score-loss 小增益, 而非神经模型单独胜出
Pairwise root-action ranker	用同一根状态内动作对训练排序的高维动作模型	当前是弱正向诊断, 不是最终突破

2 问题定义与资源模型

给定布尔函数 $f : \{0, 1\}^n \rightarrow \{0, 1\}$, 目标是构造量子 oracle

$$|x\rangle|y\rangle \mapsto |x\rangle|y \oplus f(x)\rangle.$$

若将 f 写成 ANF:

$$f(x) = \bigoplus_{m \in \mathcal{M}} \prod_{i \in m} x_i,$$

直接为每个单项式构造可逆乘法结构是语义透明的, 但在高次数、稠密或随机项集合上会产生大量重复计算。本文的搜索目标是寻找可复用因子, 把重复的 AND 结构压缩为可 compute/uncompute 的中间量, 同时控制 CNOT、深度和辅助比特开销。

实验中的候选选择采用统一逻辑层分数

$$\text{score} = T + 0.04 \text{ CNOT} + 0.015 \text{ depth} + 0.01 \text{ gates} + 2 \text{ ancilla}. \quad (1)$$

式 (1) 是可复现的逻辑层评价指标, 不是具体硬件平台的真实物理成本。因此, 论文主张应写成低 T-count 与低加权逻辑资源优势; 不能写成硬件映射最优, 也不能写成 CNOT-only 全局支配。

3 方法主线

3.1 ANF/FPRM 因子空间

本文搜索空间由三类结构组成。第一类是公共单项式因子。若多个 ANF 项共享 $g(x)$, 则可以先将 $g(x)$ 计算到辅助位, 在多个剩余子项中复用, 最后 uncompute。第二类是 FPRM 极性搜索。通过固定变量极性改变项集合形状, 可以暴露 ANF 中不可见的公共因子。第三类是 linear-pair 因子。如果局部项集合可以写成

$$(x_i \oplus x_j \oplus \dots) \cdot h(x),$$

线性部分可以用 CNOT-only 方式计算, 通常不增加 T-count。高维 $n = 14$ 到 $n = 18$ 的压力测试表明, linear-pair guard 是当前最重要的规模机制。

表 2: $n \leq 6$ 传统函数切片上的平均逻辑资源。

方法	平均 T	平均 CNOT	平均 depth	平均 ancilla	平均 score
Direct ANF	184.1	134.2	134.6	1.33	194.3
AND-direct ANF	101.0	166.5	166.9	2.18	115.2
Affine-NMCTS	45.9	94.4	98.9	1.88	55.4
Resource-NMCTS	43.9	89.9	94.5	1.92	53.2
Pareto-Resource-NMCTS	40.4	83.0	88.0	2.03	49.6
ESOP-MILP	83.6	133.5	159.6	2.32	96.7
SSHR-H	81.0	67.6	88.7	1.36	88.2

3.2 神经先验与 MCTS

搜索状态为当前尚未综合的项集合，动作为选择一个候选因子并递归处理剩余项。动作特征包括项数、平均次数、候选覆盖率、因子大小、即时资源收益和子问题规模等。神经动作先验用于给候选排序，MCTS 在固定预算内探索不同因子组合。portfolio 层会同时保留 direct ANF、AND-direct ANF、FPRM root beam、linear-pair guard、Affine-NMCTS、Resource-NMCTS 和 Pareto-Resource-NMCTS 等候选，再按式 (1) 选择正确且分数最低的线路。

高维场景中，神经模型单独控制递归排序有退化风险。因此当前更可信的设计是 baseline-preserving AI guard：同时运行 deterministic recursive guard 和 root-neural recursive guard，并选择 score 更低者。它牺牲一部分运行时间，换取无 score-loss 的保守增益。

4 当前证据

4.1 传统函数切片

$n \leq 6$ 的 177 个传统函数仍是最强主结果来源。表 2 显示，Pareto-Resource-NMCTS 在 T-count、depth 和 score 上显著优于 direct ANF、AND-direct ANF、ESOP-MILP 与 SSHR-H，但 SSHR-H 在平均 CNOT 上仍更低。因此本文不能主张 CNOT-only 最优。

相对 ESOP cube beam，Pareto-Resource-NMCTS 的 score 胜/负/平为 174/0/3，平均 score 降低 36.09%。相对 weighted ESOP-MILP，胜/负/平为 167/3/7，平均 score 降低 29.84%。这部分析足以支撑“相同 benchmark 下低 T 与低 score 优势”的主张。

4.2 高维压力测试

高维结果的核心是可扩展的 bounded search，而不是全局最优证书。表 3 汇总当前可写入论文的高维证据。

从 direct ANF 角度看， $n = 16$ 上 Resource-NMCTS 平均 T-count 降低 63.36%，平均 score 降低 60.83%； $n = 18$ 上平均 T-count 降低 60.05%，平均 score 降低 56.99%。但相对 direct ANF，CNOT、depth 和 peak ancilla 往往上升，所以这一结果应解释为用更多 Clifford/辅助结构换取明显 T-count 与 score 降低。

表 3: 高维随机 ANF 压力测试中的主要比较。

规模	对比	函数数	score 胜/负/平	平均 Δ score
$n = 14$	linear-pair guard vs root beam	64	60/0/4	-3.00%
$n = 15$	recursive guard vs root beam	32	30/0/2	-5.28%
$n = 16$	Resource-NMCTS vs root beam	24	23/0/1	-4.36%
$n = 16$	AI guard vs recursive guard	24	6/0/18	-0.05%
$n = 18$	fast guard vs root beam	12	6/0/6	-1.91%
$n = 18$	Resource-NMCTS vs fast guard	12	12/0/0	-3.55%

表 4: 高维 pairwise root-action ranker 的阶段性能结果。

比较	函数数	score 胜/负/平	平均 Δ score
Oracle top-24 vs heuristic top-1	10	7/0/3	-0.43%
Oracle top-24 vs heuristic top-4	10	3/0/7	-0.18%
Pairwise neural top-4 vs heuristic top-4	10	2/1/7	-0.01%
Pairwise learned prior vs no-prior final synthesis	12	2/0/10	-0.04%

4.3 Pairwise root-action ranker 的新增结果

上一阶段的高维 learned prior 结果很弱：在 12 个 $n = 14$ 函数上，learned prior 相对 no-prior 的 score 胜/负/平为 1/0/11，平均 score 只降低 0.01%，运行时间增加约 104.07%。这说明 immediate-gain 标签没有有效学到高维根动作排序。

新增 pairwise root-action ranker 改用同一根状态内的动作对进行训练，并用 root-teacher 标签鼓励更好动作排在更前。诊断结果见表 4。它把 final highdim neural prior 的 score 胜/负/平提高到 2/0/10，平均 score 降低 0.04%；root-action 诊断中 neural top-4 相对 heuristic top-4 变为 2/1/7，平均 score 降低 0.01%。这说明 pairwise 训练确实降低了负迁移，但幅度仍小，且 final synthesis 运行时间增加 124.91%。因此这不是目标结束点，只能写成下一轮高维 AI 改进的起点。

5 与相关工作的关系

XAG oracle synthesis 把 XOR 与 AND 结构分开，使 AND 节点数量与 T-count 密切相关 [1, 2]。ROS 将 oracle synthesis 建模为 resource-constrained LUT mapping [3]。BDD-based reversible synthesis 则以决策图方式处理较大布尔函数 [4]。这些方法都说明中间表示决定 oracle 资源结构。本文的差异是把 ANF/FPRM 项集合本身作为搜索对象，并把因子选择交给资源感知神经 MCTS/portfolio。

在 AI-guided synthesis 方向，ShortCircuit 使用 AlphaZero 风格搜索生成经典布尔电路 [6]；Gumbel AlphaZero 被用于 Clifford+T unitary synthesis [7]；ZX-calculus 优化中出现了 PPO 和图神经网络驱动的 rewrite-rule 选择 [8]；MonteQ 使用 MCTS 处理量子线路综合中的动作排序 [9]。这些工作支持学习式搜索可以用于综合问题，但它们的搜索对象不是 ANF/FPRM Boolean oracle factorization。因此本文的新意不应写成简单的“RL + MCTS”，而应写成“面向 Boolean oracle 资源模型的符号因子搜索与神经排序”。

6 当前缺口与下一步目标

当前结果已经能形成一篇逻辑层方法论文的雏形，但还没有达到“明显提升后结束”的目标。投稿前最需要补齐三件事。

第一，高维神经排序必须从弱正向变成可见增益。pairwise root-action ranker 已经把负迁移压低，但 0.04% 的 score 改善不足以支撑强 AI 主张。下一步应训练更强的 root-action/value ranker，例如扩大 teacher width、加入 top-k distillation、使用 pairwise/listwise 混合损失，并在 $n = 14, 16$ 上报告 matched no-prior、heuristic-prior 和 learned-prior 三组对比。

第二，外部 reversible-toolchain baseline 需要继续增强。当前已有 ABC、BDD、ESOP、SSHR 和 exact 小规模参照，但 ROS、mockturtle/RevKit 风格流程仍是审稿人可能追问的空白。若能在导出的 benchmark 上复现至少一个更接近 reversible oracle synthesis 的工具链，论文可信度会明显提高。

第三，需要补代表性线路案例。表格能说明资源下降，但不能说明为什么下降。建议选择 2 到 3 个函数，展示 direct ANF、root beam、linear-pair guard 和 Resource-NMCTS 的项集合分解过程，解释哪些公共因子或线性因子被发现，以及它们如何换取 T-count 降低。

7 建议的论文结构

正式英文稿可以按以下结构推进。第一节 Introduction 先从 Boolean oracle 的容错资源代价切入，再指出 ANF 透明但重复计算严重，最后提出 ANF/FPRM 资源搜索。第二节 Related work 按 XAG/LUT/BDD、SSHR、AI-guided synthesis 三类组织，不按时间堆文献。第三节 Method 严格区分资源模型、因子搜索空间、神经 MCTS、baseline-preserving guard 和 portfolio/Pareto archive。第四节 Experiments 先给 benchmark 和 baseline，再给传统函数主结果、高维压力测试、消融、exact 参照和鲁棒性。第五节 Discussion 主动承认 CNOT trade-off、高维 learned prior 仍弱、硬件映射未覆盖。第六节 Conclusion 只总结逻辑层低 T-count 与低 score 优势，不扩张到硬件或全局最优。

8 结论

本文当前最稳的主线是：Resource-NMCTS 将量子布尔函数 oracle 综合转化为 ANF/FPRM 项集合上的资源约束搜索，并通过神经先验、MCTS、linear-pair guard 和 portfolio selection 获得逻辑层低 T-count 与低加权 score 优势。传统函数和高维随机 ANF 已经给出可写入论文的结果，pairwise root-action ranker 也提供了更合理的高维 AI 训练方向。与此同时，高维 learned prior 的实际收益仍小，外部 reversible-toolchain 对比和线路案例仍需补强。因此，这份文档应作为下一轮实验和正式英文稿的路线图，而不是最终定稿。

参考文献

- [1] G. Meuli, M. Soeken, and G. De Micheli. Xor-And-Inverter Graphs for quantum compilation. *npj Quantum Information*, 8:7, 2022.

- [2] G. Meuli, M. Soeken, E. Campbell, M. Roetteler, and G. De Micheli. The role of multiplicative complexity in compiling low T-count oracle circuits. In *Proceedings of ICCAD*, 2019.
- [3] G. Meuli, M. Soeken, M. Roetteler, and G. De Micheli. ROS: Resource-constrained oracle synthesis for quantum computers. *Electronic Proceedings in Theoretical Computer Science*, 318:119–130, 2020.
- [4] R. Wille and R. Drechsler. BDD-based synthesis of reversible logic for large functions. In *Proceedings of DAC*, pp. 270–275, 2009.
- [5] Q. Zheng, Y. Xu, J. Zhang, Z. Su, and S. Zheng. CNOT oriented synthesis for small-scale Boolean functions using spatial structures of parallelotopes. *arXiv:2509.01912*, 2025.
- [6] D. Tsaras, A. Grosnit, L. Chen, Z. Xie, H. Bou-Ammar, and M. Yuan. ShortCircuit: AlphaZero-driven synthesis of Boolean circuits. *arXiv:2408.09858*, 2024.
- [7] P. Rietsch, C. T. Hann, M. Soeken, and M. Roetteler. Unitary synthesis of Clifford+T circuits with reinforcement learning. In *IEEE International Conference on Quantum Computing and Engineering*, 2024.
- [8] D. Riu, G. Nogue, J. Vilaplana, A. Garcia-Saez, and M. Estarellas. Reinforcement learning based quantum circuit optimization via ZX-calculus. *Quantum*, 9:1758, 2025.
- [9] H. Machiya, M. Menickelly, P. Hovland, and X. Liu. MonteQ: A Monte Carlo tree search based quantum circuit synthesis framework. *arXiv:2604.19029*, 2026.